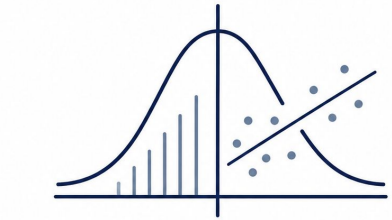
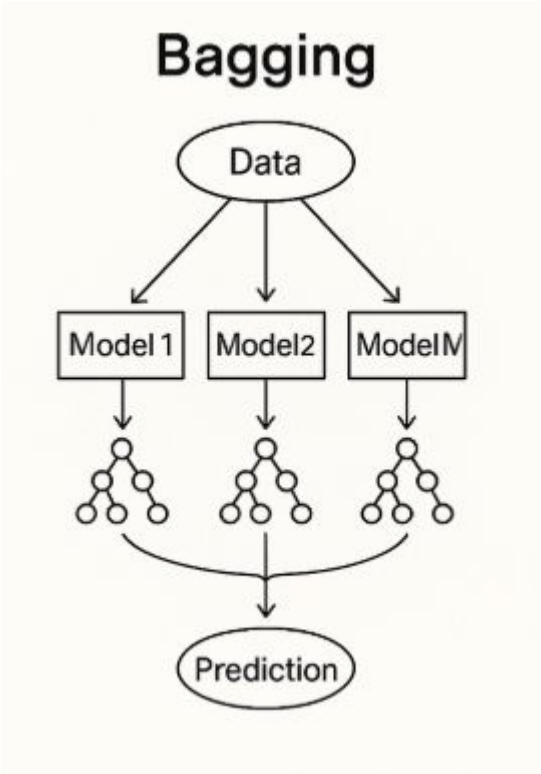
Métodos de ensamble pt.2



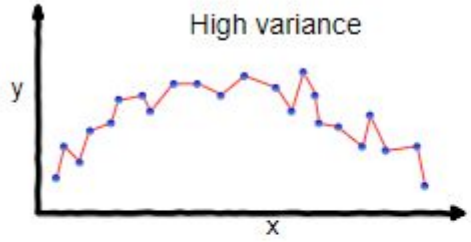
APRENDIZAJE
DE MÁQUINA
(ESTADÍSTICO)

ITAM

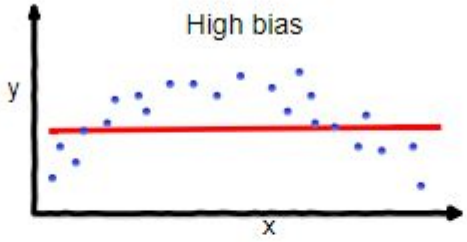
Retomando Bagging



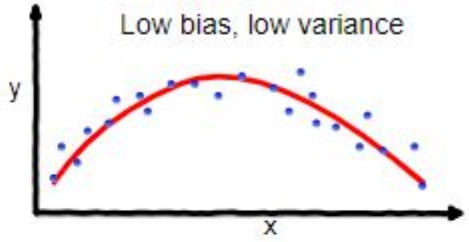
¿Y el sesgo?



overfitting

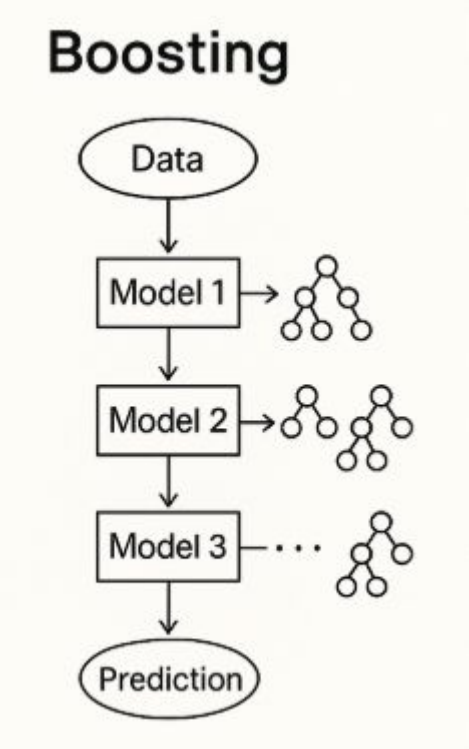


underfitting



Good balance

Boosting: Aprende de los errores de los demás



Boosting

Entrada

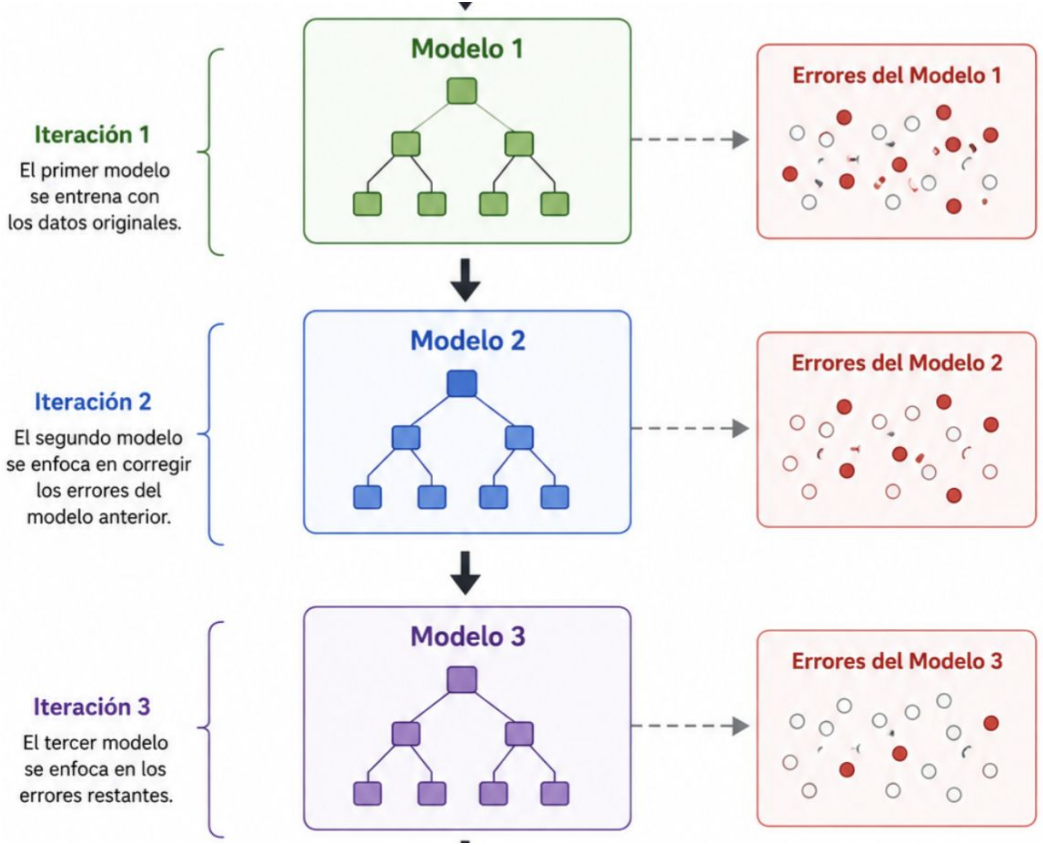
- Dataset D.
- Número de iteraciones M.

Procedimiento

1. Inicializar un modelo sencillo.
2. Para $m = 1, \ldots, M$
   a) Evaluar los errores del modelo actual.
   b) Entrenar un nuevo modelo concentrándose en dichos errores.
   c) Incorporar el nuevo modelo al ensamble.
3. Repetir hasta completar las M iteraciones.

Salida
Modelo final

Boosting



$$F_M(x) = F_0(x) + \sum_{m=1}^{M} h_m(x)$$

Ejemplo numérico

x	y
1	10
2	12
3	18
4	20

$$F_M(x) = F_0(x) + \sum_{m=1}^{M} h_m(x)$$

1. Estimador inicial simple (la media)

$$F_0(x) = \bar{y}$$

$$F_0(x) = \frac{10 + 12 + 18 + 20}{4} = 15.$$

$$\boxed{F_M(x) = F_0(x) + \sum_{m=1}^{M} h_m(x)}$$

1b. Calculamos residuos

x_i	1	2	3	4
y_i	10	12	18	20
$F_0(x_i)$	15	15	15	15
$r_i^{(1)}$	-5	-3	3	5

2. Entrenamos un árbol para predecir los residuos (X vs ri)

x_i	1	2	3	4
y_i	10	12	18	20
$F_0(x_i)$	15	15	15	15
$r_i^{(1)}$	-5	-3	3	5

Supongamos que el árbol encuentra la división

$$x \leq 2 \qquad \text{vs.} \qquad x > 2.$$

Para la primera hoja:

$$\frac{-5 + (-3)}{2} = -4.$$

Para la segunda hoja:

$$\frac{3 + 5}{2} = 4.$$

Por lo tanto, el primer árbol es

$$h_1(x) = \begin{cases} -4, & x \leq 2, \\ 4, & x > 2. \end{cases}$$

2b. Agregamos el modelo (árbol)

$$F_1(x) = F_0(x) + h_1(x).$$

Entonces,

x_i	1	2	3	4
y_i	10	12	18	20
$F_0(x_i)$	15	15	15	15
$h_1(x_i)$	-4	-4	4	4
$F_1(x_i)$	11	11	19	19

2c. Actualizamos residuos

$$r_i^{(2)} = y_i - F_1(x_i).$$

Por lo tanto,

x_i	1	2	3	4
y_i	10	12	18	20
$F_1(x_i)$	11	11	19	19
$r_i^{(2)}$	-1	1	-1	1

Los errores ahora son mucho menores:

$$(-5, -3, 3, 5) \quad \longrightarrow \quad (-1, 1, -1, 1).$$

3. Entrenamos un segundo árbol sobre los residuos del árbol anterior

Supongamos, para simplificar, que obtiene:

$$h_2(x_i) = (-1, 1, -1, 1).$$

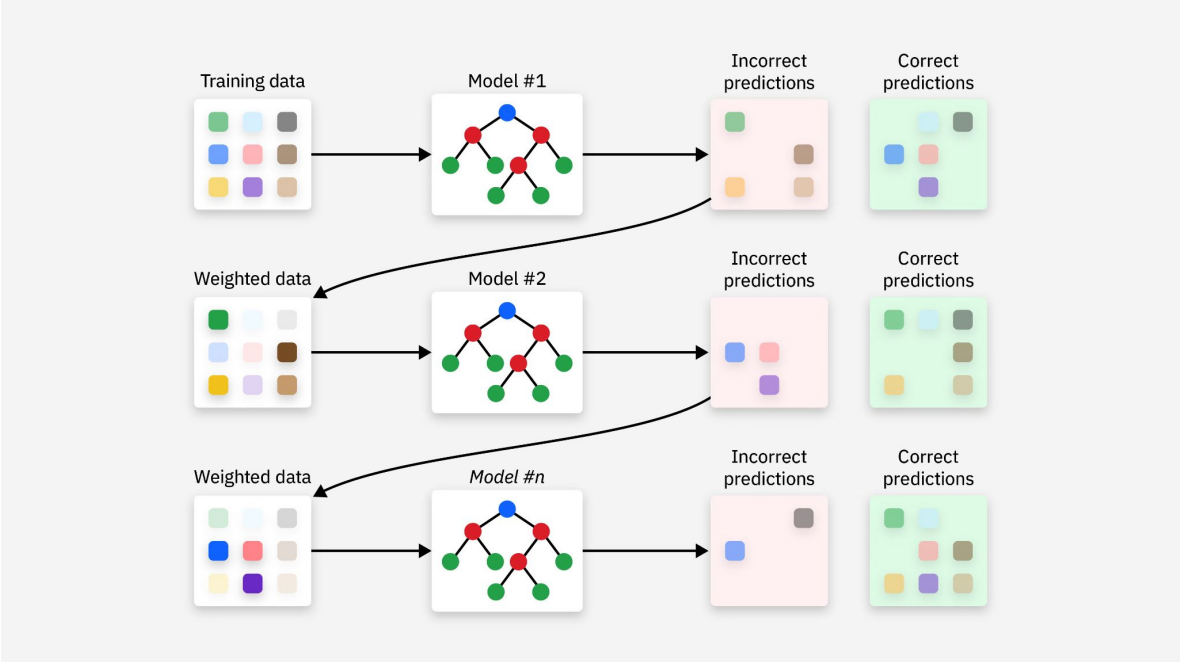
Actualizamos nuevamente:

$$F_2(x) = F_1(x) + h_2(x).$$

Entonces,

x_i	1	2	3	4
y_i	10	12	18	20
$F_1(x_i)$	11	11	19	19
$h_2(x_i)$	-1	1	-1	1
$F_2(x_i)$	10	12	18	20

Gradient Boosting (*Refuerzo de gradiente*)



$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x),$$

donde

- $F_{m-1}(x)$ corresponde al ensamble construido hasta la iteración anterior.
- $h_m(x)$ representa el nuevo árbol entrenado.
- γ_m es el peso asignado al nuevo árbol.

Entrada

- Conjunto de entrenamiento

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}.$$

- Función de pérdida $L(y, F(\mathbf{x}))$.
- Número de iteraciones M.
- Tasa de aprendizaje η.

Procedimiento

1. Inicializar el modelo resolviendo

$$F_0(\mathbf{x}) = \arg\min_{\gamma} \sum_{i=1}^{n} L(y_i, \gamma).$$

2. Para $m = 1, \ldots, M$:

   a) Calcular los pseudo-residuos (gradiente negativo)

$$r_i^{(m)} = - \left. \frac{\partial L(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right|_{F=F_{m-1}}, \qquad i = 1, \ldots, n.$$

b) Entrenar un árbol de regresión

$$h_m(\mathbf{x})$$

utilizando como variable objetivo los pseudo-residuos

$$\{(\mathbf{x}_i, r_i^{(m)})\}_{i=1}^n.$$

c) Calcular el peso óptimo

$$\gamma_m = \arg\min_{\gamma} \sum_{i=1}^{n} L\left(y_i, F_{m-1}(\mathbf{x}_i) + \gamma h_m(\mathbf{x}_i)\right).$$

d) Actualizar el modelo

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, \gamma_m h_m(\mathbf{x}).$$

Salida
Modelo final

$$\boxed{F_M(\mathbf{x}).}$$

1. Modelo inicial

x_i	1	2	3	4
y_i	10	12	18	20

Utilizamos como función de pérdida el error cuadrático:

$$L(y_i, F(x_i)) = \frac{1}{2}\left(y_i - F(x_i)\right)^2.$$

El modelo inicial que minimiza esta pérdida es la media:

$$F_0(x) = \bar{y} = \frac{10 + 12 + 18 + 20}{4} = 15.$$

Por lo tanto,

$$F_0(x_i) = (15, 15, 15, 15).$$

2. Cálculo de gradiente negativo

Derivamos respecto a la predicción:

$$\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} = F(x_i) - y_i.$$

Por lo tanto, el gradiente negativo es:

$$-\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} = y_i - F(x_i).$$

Para MSE, el gradiente negativo coincide exactamente con el residuo:

$$\boxed{r_i^{(1)} = y_i - F_0(x_i)}$$

3. Cálculo de residuos con gradiente negativo

x_i	1	2	3	4
y_i	10	12	18	20
$F_0(x_i)$	15	15	15	15
$r_i^{(1)}$	-5	-3	3	5

4. Entrenar árbol para predecir residuos (gradiente negativo)

Supongamos que el árbol encuentra la división

$$x \leq 2 \qquad \text{vs.} \qquad x > 2.$$

En la primera hoja:

$$\frac{-5 + (-3)}{2} = -4.$$

En la segunda hoja:

$$\frac{3 + 5}{2} = 4.$$

Por lo tanto,

$$h_1(x) = \begin{cases} -4, & x \leq 2, \\ 4, & x > 2. \end{cases}$$

Es decir,

$$h_1(x_i) = (-4, -4, 4, 4).$$

5. Actualizar ensamble

La actualización de Gradient Boosting es:

$$F_1(x) = F_0(x) + \eta h_1(x),$$

donde η es el learning rate.
Para simplificar el ejemplo, utilizamos

$$\eta = 1.$$

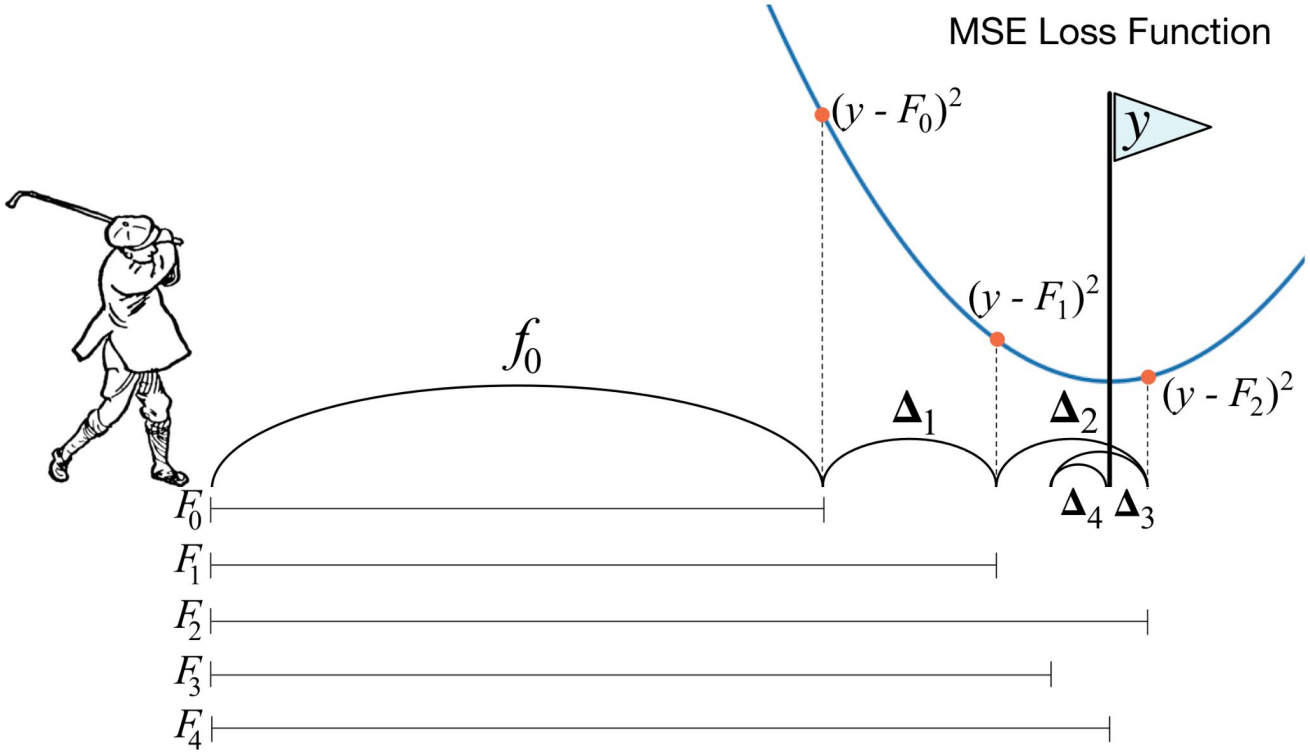
Entonces,

$$F_1(x) = F_0(x) + h_1(x).$$

Por lo tanto,

x_i	1	2	3	4
y_i	10	12	18	20
$F_0(x_i)$	15	15	15	15
$h_1(x_i)$	-4	-4	4	4
$F_1(x_i)$	11	11	19	19

¿Les recuerda a alguien?



Idea general

En cada iteración m:

$$\boxed{r_i^{(m)} = -\left.\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)}\right|_{F=F_{m-1}}}$$

Se entrena un nuevo árbol:

$$h_m(x) \approx r_i^{(m)}$$

y se actualiza el ensamble:

$$\boxed{F_m(x) = F_{m-1}(x) + \eta h_m(x)}$$

Para el caso particular del MSE:

$$\boxed{r_i^{(m)} = y_i - F_{m-1}(x_i)}$$

¿Y la clasificación?

De hecho, es similar a la regresión. Solo cambia la función de pérdida.

$$J(\beta) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(\hat{p}_i) + (1-y_i)\log(1-\hat{p}_i)\right]$$

Ejemplo

Observación	X	Y
A	1	0
B	2	0
C	3	1
D	4	1

Parámetro	Valor
`n_estimators`	2
`learning_rate`	$\eta = 0.5$
`max_depth`	1

Ejemplo

$$\mathcal{L}(F) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(\hat{p}_i) + (1-y_i)\log(1-\hat{p}_i)\right]$$

La predicción interna del ensamble es $F(x)$, y la probabilidad de clase 1 es

$$\hat{p}_i = \sigma(F(x_i)) = \frac{1}{1+e^{-F(x_i)}}.$$

1. Predicción inicial

En el conjunto de datos hay dos observaciones con $Y = 1$ y dos con $Y = 0$. Por tanto, la probabilidad inicial es $\hat{p}_0 = 2/4 = 0.5$, y la predicción inicial en log-odds es

$$F_0 = \log\left(\frac{0.5}{1 - 0.5}\right) = 0.$$

Así, para las cuatro observaciones, $\hat{p}_{i,0} = \sigma(0) = 0.5$. Sustituyendo en la ecuación (1):

$$\boxed{\mathcal{L}_0 = -\log(0.5) = 0.6931.} \tag{3}$$

2. Cálculo de pseudo residuos

Para cada observación, el **gradiente negativo** de la log-loss respecto a la predicción interna es

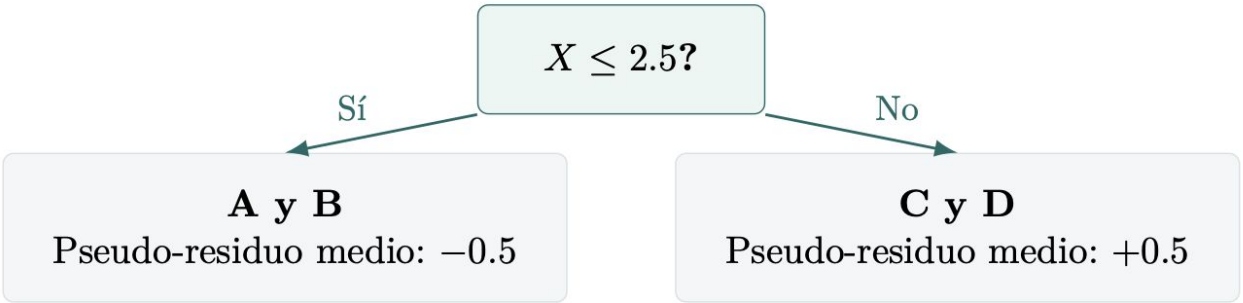
$$\frac{\partial \ell_i}{\partial F(x_i)} = \hat{p}_i - y_i, \qquad \boxed{r_{i,m} = y_i - \hat{p}_{i,m-1}.} \tag{4}$$

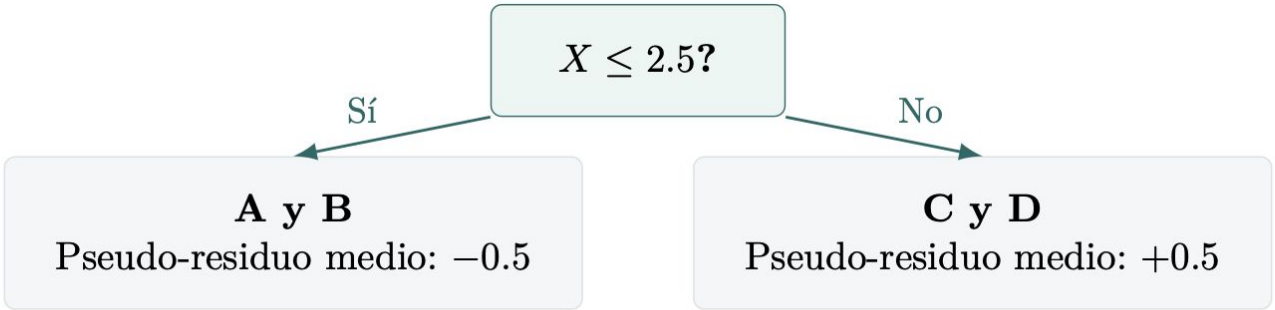
En la primera iteración, $\hat{p}_{i,0} = 0.5$:

Observación	y_i	$\hat{p}_{i,0}$	$r_{i,1} = y_i - \hat{p}_{i,0}$
A	0	0.500	-0.500
B	0	0.500	-0.500
C	1	0.500	$+0.500$
D	1	0.500	$+0.500$

3. Ajuste de primer árbol de regresión

Ajustamos un árbol de *regresión* a los pseudo-residuos. Con profundidad máxima igual a 1, una división natural es $X \leq 2.5$.





Importante: el promedio de pseudo-residuos sirve para ajustar el árbol, pero la **actualización final** de cada hoja se calcula mediante un paso de Newton:

$$\boxed{\gamma_{j,m} = \frac{\sum_{i \in R_{j,m}} (y_i - \hat{p}_{i,m-1})}{\sum_{i \in R_{j,m}} \hat{p}_{i,m-1}(1 - \hat{p}_{i,m-1})}}. \tag{5}$$

$$\gamma_{\text{izq},1} = \frac{-0.5 - 0.5}{0.5(0.5) + 0.5(0.5)} = \boxed{-2},$$

$$\gamma_{\text{der},1} = \frac{+0.5 + 0.5}{0.5(0.5) + 0.5(0.5)} = \boxed{+2}.$$

4. Primera actualización del ensamble

La predicción interna se actualiza sumando la contribución de este árbol con un factor de aprendizaje $\eta = 0.5$:

$$F_1(x) = F_0(x) + \eta\gamma_1(x).$$

Así, para A y B, $F_1 = -1$; para C y D, $F_1 = +1$. La pérdida disminuye a $\mathcal{L}_1 = -\log(\sigma(1)) \approx 0.3133$.

Observación	y_i	$F_1(x_i)$	$\hat{p}_{i,0}$	$\hat{p}_{i,1} = \sigma(F_1)$
A	0	-1	0.500	0.269
B	0	-1	0.500	0.269
C	1	$+1$	0.500	0.731
D	1	$+1$	0.500	0.731

4. Primera actualización del ensamble

La predicción interna se actualiza sumando la contribución de este árbol con un factor de aprendizaje $\eta = 0.5$:

$$F_1(x) = F_0(x) + \eta\gamma_1(x).$$

Así, para A y B, $F_1 = -1$; para C y D, $F_1 = +1$. La pérdida disminuye a $\mathcal{L}_1 = -\log(\sigma(1)) \approx 0.3133$.

Observación	y_i	$F_1(x_i)$	$\hat{p}_{i,0}$	$\hat{p}_{i,1} = \sigma(F_1)$
A	0	-1	0.500	0.269
B	0	-1	0.500	0.269
C	1	$+1$	0.500	0.731
D	1	$+1$	0.500	0.731

4. Primera actualización del ensamble

La predicción interna se actualiza sumando la contribución de este árbol con un factor de aprendizaje $\eta = 0.5$:

$$F_1(x) = F_0(x) + \eta\gamma_1(x).$$

Así, para A y B, $F_1 = -1$; para C y D, $F_1 = +1$. La pérdida disminuye a $\mathcal{L}_1 = -\log(\sigma(1)) \approx 0.3133$.

Observación	y_i	$F_1(x_i)$	$\hat{p}_{i,0}$	$\hat{p}_{i,1} = \sigma(F_1)$
A	0	-1	0.500	0.269
B	0	-1	0.500	0.269
C	1	$+1$	0.500	0.731
D	1	$+1$	0.500	0.731

5. Segundo árbol

Volvemos a calcular los pseudo-residuos a partir de las nuevas probabilidades:

Observación	y_i	$\hat{p}_{i,1}$	$r_{i,2} = y_i - \hat{p}_{i,1}$
A	0	0.2689	-0.2689
B	0	0.2689	-0.2689
C	1	0.7311	$+0.2689$
D	1	0.7311	$+0.2689$

El segundo árbol vuelve a elegir la división $X \leq 2.5$. Aplicamos de nuevo la ecuación (5). Para la hoja derecha:

$$\begin{aligned}\gamma_{\text{der},2} &= \frac{0.2689 + 0.2689}{0.7311(1-0.7311) + 0.7311(1-0.7311)} \\ &\approx \boxed{1.3679}.\end{aligned}$$

Por simetría, $\gamma_{\text{izq},2} \approx -1.3679$. La nueva predicción interna es

$$\begin{aligned}F_2(x) &= F_1(x) + 0.5\,\gamma_2(x), \\ F_2(\text{A},\text{B}) &= -1 + 0.5(-1.3679) \approx -1.6839, \\ F_2(\text{C},\text{D}) &= +1 + 0.5(+1.3679) \approx +1.6839.\end{aligned}$$

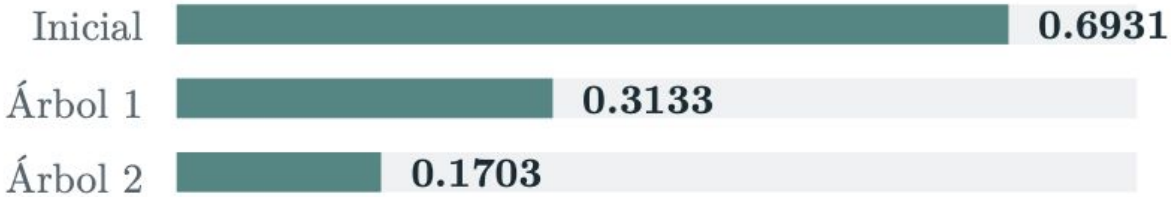
5b. Aplicamos sigmoide ya que estamos en términos de log odds

$$\hat{p}_2(\mathrm{A},\mathrm{B}) = \sigma(-1.6839) \approx 0.1566, \qquad \hat{p}_2(\mathrm{C},\mathrm{D}) = \sigma(+1.6839) \approx 0.8434.$$

$$\boxed{\mathcal{L}_2 = -\log(0.8434) \approx 0.1703.}$$

Resultado Final

Obs.	y_i	$\hat{p}_{i,0}$	$\hat{p}_{i,1}$	$\hat{p}_{i,2}$
A	0	0.5000	0.2689	**0.1566**
B	0	0.5000	0.2689	**0.1566**
C	1	0.5000	0.7311	**0.8434**
D	1	0.5000	0.7311	**0.8434**

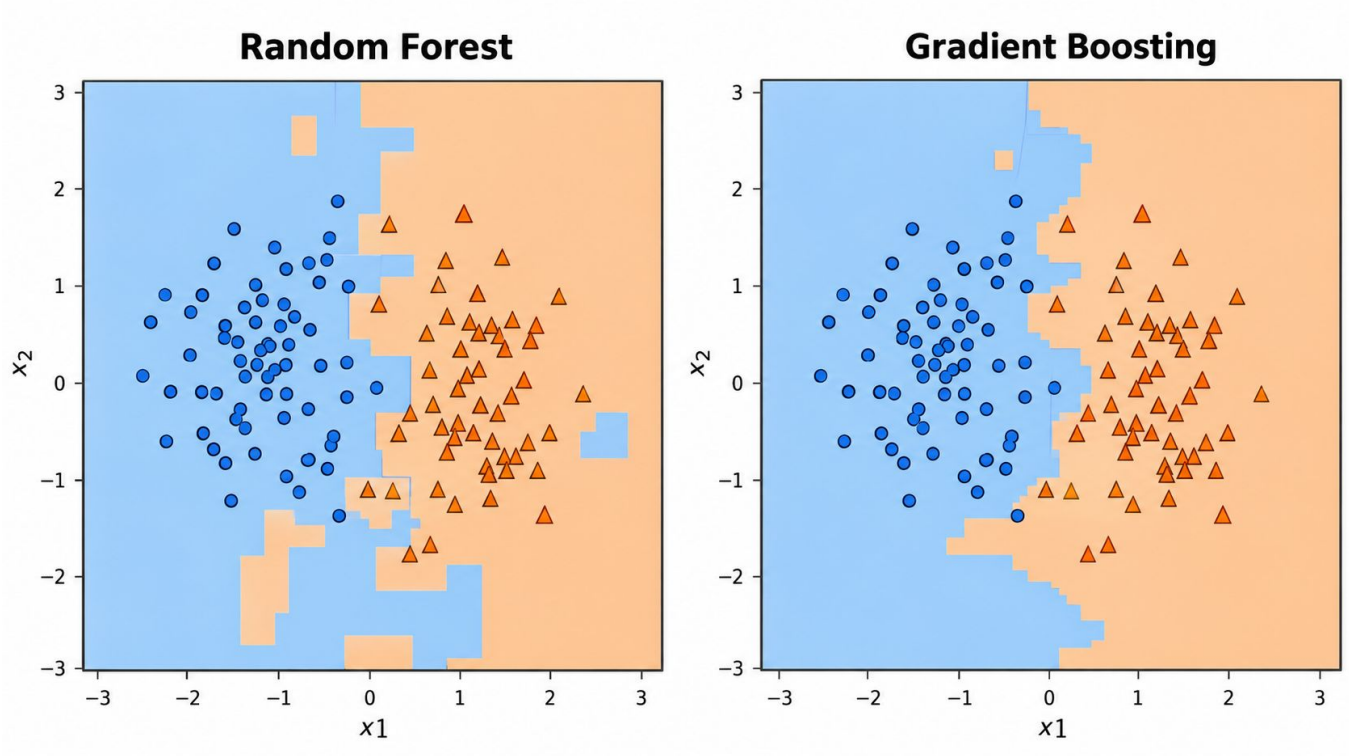


Conclusión. Cada árbol es un modelo de regresión que aproxima el gradiente negativo de la log-loss. Sus hojas generan correcciones a los *log-odds*, no directamente a las clases. El ensamble final toma la forma

$$\boxed{F_2(x) = F_0(x) + \eta\gamma_1(x) + \eta\gamma_2(x), \qquad \hat{p}_2(x) = \sigma(F_2(x)).}$$

Hiperparámetro	¿Qué controla?	Si aumenta…
`n_estimators`	Número de etapas de boosting	↓ Sesgo, posible ↑ varianza
`learning_rate`	Contribución de cada árbol	↓ Sesgo más rápídamente, posible ↑ varianza
`max_depth`	Profundidad máxima de cada árbol	↓ Sesgo, ↑ varianza
`min_samples_split`	Mínimo de observaciones para dividir un nodo	↑ Sesgo, ↓ varianza
`min_samples_leaf`	Mínimo de observaciones por hoja	↑ Sesgo, ↓ varianza
`subsample`	Fracción de observaciones utilizadas por árbol	Generalmente ↓ sesgo y ↑ varianza al acercarse a 1
`max_features`	Variables candidatas consideradas en cada división	Puede ↓ sesgo y ↑ varianza
`max_leaf_nodes`	Número máximo de hojas de cada árbol	↓ Sesgo, ↑ varianza
`n_iter_no_change`	Paciencia para detener el entrenamiento	Controla el sobreajuste mediante early stopping

Fronteras de decisión



Método	**Idea principal**	**Principal beneficio**
Bagging	Entrenar múltiples modelos independientes sobre muestras bootstrap y combinar sus predicciones.	Reduce la varianza del modelo.
Random Forest	Aplica Bagging sobre árboles de decisión e incorpora selección aleatoria de variables en cada nodo.	Reduce la varianza y disminuye la correlación entre árboles.
Boosting	Entrena los modelos de forma secuencial, haciendo que cada nuevo modelo aprenda de los errores de los anteriores.	Reduce principalmente el sesgo del modelo.
Gradient Boosting	Interpreta el entrenamiento secuencial como un problema de optimización mediante gradientes.	Mejora progresivamente el ajuste minimizando una función de pérdida.