

Aprendizaje de Máquina

Tarea 3 Optimización de la Regresión Lineal

Braulio Piña Amaros

“Aprender un modelo consiste en encontrar los parámetros que hacen que sus errores sean tan pequeños como sea posible.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar la regresión lineal como un problema de optimización.
- Calcular e interpretar residuos.
- Construir una función de pérdida a partir de los errores del modelo.
- Explicar por qué los errores se elevan al cuadrado en el método de mínimos cuadrados.
- Derivar la solución analítica de una regresión lineal simple.
- Interpretar el gradiente de una función.
- Realizar manualmente iteraciones de descenso por gradiente.
- Comparar descenso por gradiente y descenso por gradiente estocástico.
- Analizar el efecto de la tasa de aprendizaje sobre la convergencia.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los pasos de tus derivaciones y cálculos.
- No necesitas utilizar ningún lenguaje de programación.
- Puedes utilizar calculadora o el lenguaje de programación que quieras (usalo como calculadora), las notas del curso y bibliografía adicional.

- Salvo que se indique lo contrario, conserva al menos cuatro decimales durante los cálculos.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. Del valor observado al residuo

Una empresa utiliza el siguiente modelo para estimar el tiempo de entrega de un pedido:

$$\hat{y}_i = 12 + 3x_i,$$

donde x_i representa la distancia recorrida, medida en kilómetros, y y_i representa el tiempo real de entrega, medido en minutos.

Se observan los siguientes pedidos:

Pedido	Distancia x_i	Tiempo observado y_i	Tiempo estimado $\hat{y}_i$
1	1	17	
2	2	16	
3	3	24	
4	4	27	
5	5	30	

Define el residuo de la observación i como:

$$e_i = y_i - \hat{y}_i.$$

- a) Calcula la predicción $\hat{y}_i$ para cada pedido.
- b) Calcula el residuo de cada observación.
- c) Identifica las observaciones para las cuales el modelo:
 - I) subestima el tiempo de entrega;
 - II) sobreestima el tiempo de entrega;
 - III) predice exactamente el valor observado.
- d) Calcula la suma de los residuos:

$$\sum_{i=1}^5 e_i.$$

- e) Supón que la suma de los residuos fuera igual a cero. ¿Podrías concluir que el modelo no comete errores? Justifica tu respuesta.

Caso 2. Elegir la mejor recta

Considera el siguiente conjunto de datos:

x_i	y_i
0	1
1	3
2	4
3	8

Tres analistas proponen los siguientes modelos:

Modelo A: $\hat{y} = 1 + 2x,$

Modelo B: $\hat{y} = 2 + x,$

Para cada modelo:

- a) Calcula las cuatro predicciones.
- b) Calcula la suma de errores cuadrados:

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

- c) Calcula el error cuadrático medio:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Después responde:

- a) ¿Cuál de los tres modelos elegirías utilizando como criterio el MSE?
- b) ¿Cambiaría tu elección si utilizaras el SSE? Explica por qué.

Caso 3. La solución analítica

Considera una regresión lineal simple:

$$\hat{y}_i = \beta_0 + \beta_1 x_i,$$

con la siguiente función objetivo:

$$J(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Parte I. Derivación

- a) Calcula la derivada parcial de J con respecto a β_0 .
- b) Calcula la derivada parcial de J con respecto a β_1 .
- c) Iguala ambas derivadas a cero y muestra que se obtienen las ecuaciones normales:

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i,$$
$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2.$$

Parte II. Aplicación

Utiliza el siguiente conjunto de datos:

x_i	y_i
1	2
2	4
3	5
4	8

- a) A partir de las ecuaciones normales tenemos que los parámetros óptimos son:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

y

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

- b) Calcula $\bar{x}$ y $\bar{y}$.
- c) Completa una tabla con las siguientes columnas:

$$x_i, \quad y_i, \quad x_i - \bar{x}, \quad y_i - \bar{y}, \quad (x_i - \bar{x})(y_i - \bar{y}), \quad (x_i - \bar{x})^2.$$

- d) Calcula $\hat{\beta}_1$.
- e) Calcula $\hat{\beta}_0$.
- f) Escribe la recta estimada.
- g) Calcula la predicción para cada observación.

h) Calcula los residuos y verifica que la suma de los residuos es igual a 0 (salvo diferencias por redondeo).

i) ¿la recta estimada pasa por el punto?:

$$(\bar{x}, \bar{y}).$$

¿Por qué?

Caso 4. El gradiente como dirección

Considera la función:

$$J(\beta_0, \beta_1) = (\beta_0 - 2)^2 + 2(\beta_1 - 3)^2.$$

a) Calcula el gradiente:

$$\nabla J(\beta_0, \beta_1) = \begin{pmatrix} \frac{\partial J}{\partial \beta_0} \\ \frac{\partial J}{\partial \beta_1} \end{pmatrix}.$$

b) Encuentra analíticamente el punto que minimiza la función.

c) Calcula el valor de la función en:

$$(\beta_0, \beta_1) = (0, 0).$$

d) Calcula el gradiente en $(0, 0)$.

e) Interpreta el signo de cada componente del gradiente.

f) Explica por qué el descenso por gradiente utiliza la dirección contraria al máximo crecimiento:

$$-\nabla J(\beta_0, \beta_1).$$

g) Utiliza una tasa de aprendizaje $\alpha = 0.1$ y realiza una actualización mediante:

$$\begin{pmatrix} \beta_0^{(t+1)} \\ \beta_1^{(t+1)} \end{pmatrix} = \begin{pmatrix} \beta_0^{(t)} \\ \beta_1^{(t)} \end{pmatrix} - \alpha \nabla J(\beta_0^{(t)}, \beta_1^{(t)}).$$

h) Calcula el valor de J después de la actualización.

i) Verifica si la función de pérdida disminuyó.

j) Repite una segunda iteración.

k) Describe hacia qué punto parecen moverse los parámetros.
