

Aprendizaje de Máquina

Tarea 4 Generalización y Regularización

Braulio Piña Amaros

“El objetivo de un modelo no es explicar perfectamente los datos que ya observó, sino funcionar correctamente frente a observaciones nuevas.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar por qué el desempeño sobre los datos de entrenamiento no es suficiente para evaluar un modelo.
- Distinguir los conjuntos de entrenamiento, validación y prueba.
- Identificar casos de subajuste y sobreajuste.
- Explicar el compromiso entre ajuste y generalización.
- Analizar el compromiso entre sesgo y varianza.
- Explicar la regularización como un mecanismo para controlar la complejidad del modelo.
- Resolver manualmente problemas sencillos de Ridge Regression.
- Analizar el efecto del hiperparámetro de regularización sobre los coeficientes.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos y desarrollos matemáticos completos.
- No necesitas utilizar ningún lenguaje de programación (pero puedes usarlo).
- Puedes utilizar calculadora, las notas del curso y bibliografía adicional.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. Datos conocidos y datos desconocidos

Una empresa cuenta con 1,000 observaciones para construir un modelo de regresión. Un analista propone entrenar el modelo utilizando las 1,000 observaciones y reportar el error calculado sobre esos mismos datos.

- a) Explica por qué evaluar el modelo únicamente con los datos utilizados durante el entrenamiento puede producir una impresión demasiado optimista de su desempeño.
- b) Explica por qué el conjunto de prueba debería permanecer sin utilizar hasta el final del proceso.
- c) Supón que se prueban 50 configuraciones diferentes y se elige la que obtiene el menor error sobre el conjunto de prueba. ¿Continúa siendo el conjunto de prueba una evaluación verdaderamente independiente? Justifica tu respuesta.
- d) Un modelo obtiene los siguientes resultados:

$$\text{MSE}_{\text{train}} = 4.2, \quad \text{MSE}_{\text{validation}} = 4.8, \quad \text{MSE}_{\text{test}} = 5.0.$$

- e) Otro modelo obtiene:

$$\text{MSE}_{\text{train}} = 0.3, \quad \text{MSE}_{\text{validation}} = 12.5, \quad \text{MSE}_{\text{test}} = 13.1.$$

Interpreta estos resultados y compara ambos modelos.

- f) Explica qué significa que un modelo generalice.

Caso 2. Ajustar no siempre significa aprender


Se entrenan cuatro modelos de distinta complejidad para predecir una variable continua. Los resultados son:

Modelo	Complejidad	MSE train	MSE validación	Número de parámetros
A	Muy baja	18.0	19.5	2
B	Baja	7.2	8.0	5
C	Media	2.1	4.0	15
D	Muy alta	0.1	16.8	120

- a) Identifica cuál de los modelos presenta mayor evidencia de subajuste.
- b) Identifica cuál presenta mayor evidencia de sobreajuste.
- c) ¿Cuál elegirías utilizando únicamente el desempeño de validación? Justifica tu respuesta.
- d) Explica por qué el Modelo D logra un error de entrenamiento tan pequeño, pero un error de validación tan grande.

- e) ¿Por qué un modelo excesivamente simple puede tener errores elevados tanto en entrenamiento como en validación?
- f) Ordena los cuatro modelos de menor a mayor complejidad.
- g) ¿Esperas que el error de entrenamiento aumente o disminuya al incrementar la complejidad? Explica.
- h) ¿Esperas que el error de validación disminuya indefinidamente al incrementar la complejidad? Explica.
- i) Supón que el Modelo C obtiene un MSE de prueba igual a 9.5, considerablemente mayor que su MSE de validación. Propón al menos tres explicaciones posibles.

La siguiente figura representa de manera esquemática el comportamiento del error conforme aumenta la complejidad del modelo.



- a) Identifica aproximadamente las regiones de:
 - I) subajuste;
 - II) equilibrio entre ajuste y generalización;
 - III) sobreajuste.
- b) ¿El mínimo del error de validación constituye un criterio razonable para seleccionar la complejidad?

Caso 3. Sesgo y varianza

Se toman cinco muestras distintas de una misma población. Sobre cada muestra se entrena un modelo y se calcula su predicción para una observación fija x_0 .

El valor verdadero es:

$$f(x_0) = 20.$$

Las predicciones obtenidas son:

Modelo	Muestra 1	Muestra 2	Muestra 3	Muestra 4	Muestra 5
A	14	15	14	15	14
B	18	23	17	24	19
C	20	20	21	19	20

Para cada modelo:

- a) Calcula la predicción promedio:

$$\overline{\hat{f}(x_0)} = \frac{1}{5} \sum_{j=1}^5 \hat{f}^{(j)}(x_0).$$

- b) Calcula el sesgo empírico:

$$\text{Sesgo} = \overline{\hat{f}(x_0)} - f(x_0).$$

- c) Calcula la varianza empírica de las predicciones utilizando:

$$\text{Varianza} = \frac{1}{5} \sum_{j=1}^5 \left(\hat{f}^{(j)}(x_0) - \overline{\hat{f}(x_0)} \right)^2.$$

- d) Clasifica cada modelo como:

- alto sesgo y baja varianza;
- bajo sesgo y alta varianza;
- bajo sesgo y baja varianza.

- e) ¿Cuál de los tres modelos elegirías? Justifica tu respuesta.

Después responde:

- a) Explica con tus propias palabras qué representa el sesgo de un modelo.
- b) Explica qué representa la varianza.
- c) ¿Por qué un modelo muy flexible suele presentar menor sesgo y mayor varianza?
- d) ¿Por qué un modelo excesivamente rígido suele presentar mayor sesgo y menor varianza?

- e) Un modelo produce prácticamente las mismas predicciones cada vez que cambia ligeramente la muestra de entrenamiento, pero dichas predicciones están sistemáticamente alejadas de los valores verdaderos. ¿Qué problema presenta?
- f) Otro modelo produce predicciones muy distintas ante pequeños cambios en la muestra. ¿Qué problema presenta?
- g) ¿Siempre es posible reducir simultáneamente el sesgo y la varianza?

Caso 4. La idea detrás de Ridge Regression

Considera un modelo lineal con dos variables predictoras:

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}.$$

La función objetivo de mínimos cuadrados es:

$$J_{\text{OLS}}(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2})^2.$$

Ridge Regression modifica esta función de la siguiente manera:

$$J_{\text{Ridge}}(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2})^2 + \lambda (\beta_1^2 + \beta_2^2),$$

donde $\lambda \geq 0$.

- a) Identifica los dos componentes de la función objetivo de Ridge. ¿Qué intentan controlar?
- b) ¿Qué pasa con la penalización cuando aumenta la magnitud de los coeficientes?
- c) ¿Qué ocurre cuando:
 - I) $\lambda = 0$;
 - II) λ es positivo pero pequeño;
 - III) λ es muy grande?
- d) Explica por qué Ridge introduce sesgo en los coeficientes.
- e) Explica por qué aceptar un poco más de sesgo puede reducir el error sobre datos nuevos.
- f) Calcula la penalización Ridge $(\beta_1^2 + \beta_2^2)$ para los siguientes pares de coeficientes:

$$\text{Modelo A: } \beta_1 = 8, \quad \beta_2 = -7,$$

$$\text{Modelo B: } \beta_1 = 3, \quad \beta_2 = -2.$$

- g) Supón que ambos modelos producen exactamente el mismo SSE. ¿Cuál sería preferido por Ridge cuando $\lambda > 0$? Justifica tu respuesta.
- h) Si el Modelo A produce un SSE ligeramente menor, ¿es posible que Ridge prefiera al Modelo B? Explica bajo qué condiciones.

Caso 5. Resolviendo un problema regularizado

Considera un modelo sin intercepto y con un único parámetro:

$$\hat{y}_i = \beta x_i.$$

Se observan los siguientes datos:

x_i	y_i
1	3
2	6

La función objetivo de Ridge es:

$$J(\beta) = \sum_{i=1}^2 (y_i - \beta x_i)^2 + \lambda \beta^2.$$

- a) Sustituye los datos y escribe $J(\beta)$ de forma explícita.
- b) Expande y simplifica la expresión.
- c) Calcula:

$$\frac{dJ(\beta)}{d\beta}.$$

- d) Iguala la derivada a cero y demuestra que la solución es:

$$\hat{\beta}_{\text{Ridge}} = \frac{15}{5 + \lambda}.$$

- e) ¿Qué ocurre con el coeficiente conforme aumenta λ ?
- f) ¿La función objetivo completa necesariamente aumenta cuando aumenta λ ? Analiza cuidadosamente, tomando en cuenta que el valor óptimo de β también cambia.