

Aprendizaje de Máquina

Tarea 5

Ingeniería y Transformación de Variables

Braulio Piña Amaros

“Un modelo sólo puede aprender a partir de la información que sus variables logran representar.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar el papel de la ingeniería de variables dentro de un proyecto de Aprendizaje de Máquina.
- Identificar variables que requieren transformación antes de ser utilizadas por un modelo.
- Representar variables categóricas mediante variables dummy y One-Hot Encoding.
- Explicar y detectar el problema conocido como Dummy Variable Trap.
- Aplicar manualmente normalización y estandarización.
- Analizar el efecto del escalamiento sobre distintos algoritmos.
- Construir variables derivadas y variables de interacción.
- Detectar casos de Data Leakage.
- Diseñar transformaciones respetando la separación entre entrenamiento, validación y prueba.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos y transformaciones completas.
- No necesitas utilizar ningún lenguaje de programación (pero puedes usarlo para cálculos).
- Puedes utilizar calculadora, las notas del curso y bibliografía adicional.
- Salvo que se indique lo contrario, conserva al menos cuatro decimales durante los cálculos.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. ¿Qué información ve realmente el modelo?

Una empresa desea construir un modelo para predecir el gasto mensual de sus clientes. La base inicial contiene las siguientes variables:

Variable	Descripción
<code>edad</code>	Edad del cliente en años
<code>fecha_nacimiento</code>	Fecha de nacimiento
<code>ingreso_mensual</code>	Ingreso mensual en pesos
<code>gasto_anual</code>	Gasto total acumulado durante el último año
<code>ciudad</code>	Ciudad de residencia
<code>codigo_postal</code>	Código postal
<code>fecha_alta</code>	Fecha de incorporación como cliente
<code>numero_compras</code>	Número de compras realizadas
<code>monto_ultima_compra</code>	Valor de la compra más reciente
<code>identificador</code>	Identificador único del cliente

- a) Identifica cuáles variables podrían utilizarse directamente en un modelo numérico y cuáles requieren algún tipo de transformación.
- b) Explica por qué una fecha normalmente no debería introducirse al modelo únicamente como una cadena de texto.
- c) Propón tres variables derivadas que podrían construirse a partir de una o combinando:
 - I) `fecha_nacimiento`;
 - II) `fecha_alta`;
 - III) `gasto_anual`;
 - IV) `numero_compras`.
- d) ¿utilizarías `identificador` como variable predictora?
- e) ¿Puede un código postal contener información útil, aunque esté representado mediante números? Explica por qué no necesariamente debería tratarse como una variable cuantitativa continua.
- f) Propón una forma de representar la información geográfica contenida en el código postal.
- g) La empresa decide utilizar directamente `gasto_anual` para predecir el gasto del mes siguiente. Explica qué precauciones temporales deberían tomarse al construir esta variable.

Caso 2. Representando variables categóricas

Una inmobiliaria utiliza las siguientes variables para estimar el precio de una vivienda:

- superficie;
- antigüedad;
- tipo de vivienda;
- zona.

Las categorías observadas son:

Tipo de vivienda $\in \{\text{Casa}, \text{Departamento}, \text{Loft}\}$,

Zona $\in \{\text{Centro}, \text{Norte}, \text{Sur}, \text{Poniente}\}$.

La muestra es:

Vivienda	Superficie	Tipo	Zona
1	80	Departamento	Centro
2	120	Casa	Norte
3	65	Loft	Centro
4	150	Casa	Poniente
5	95	Departamento	Sur
6	70	Loft	Norte

a) Explica por qué no sería adecuado representar el tipo de vivienda como:

Casa = 1, Departamento = 2, Loft = 3.

b) ¿Qué relación artificial introduciría esta codificación?

c) Construye manualmente una representación One-Hot Encoding para la variable *Zona* y para la variable *Tipo*.

d) ¿Cuántas columnas nuevas se generan en total?

e) Explica la diferencia entre una variable categórica nominal y una categórica ordinal.

f) Considera ahora la variable:

Nivel de calidad $\in \{\text{Bajo}, \text{Medio}, \text{Alto}\}$.

¿Podría tener sentido representarla como 1, 2 y 3? Explica qué supuesto se estaría introduciendo.

g) Propón una representación alternativa si no deseas asumir que la distancia entre *Bajo* y *Medio* es igual a la distancia entre *Medio* y *Alto*.

Caso 3. El Dummy Variable Trap

Considera la variable categórica:

$$\text{Canal} \in \{\text{Tienda}, \text{Web}, \text{Teléfono}\}.$$

Se construyen las siguientes variables dummy:

$$D_{\text{Tienda}}, \quad D_{\text{Web}}, \quad D_{\text{Teléfono}}.$$

Para cada observación se cumple:

$$D_{\text{Tienda}} + D_{\text{Web}} + D_{\text{Teléfono}} = 1.$$

La empresa propone estimar el modelo:

$$\hat{y} = \beta_0 + \beta_1 D_{\text{Tienda}} + \beta_2 D_{\text{Web}} + \beta_3 D_{\text{Teléfono}}.$$

- a) Explica por qué las cuatro columnas:

$$1, \quad D_{\text{Tienda}}, \quad D_{\text{Web}}, \quad D_{\text{Teléfono}}$$

son linealmente dependientes.

- b) Explica qué problema genera esta dependencia al intentar estimar una regresión lineal. ¿Cómo eliminarías el dummy variable trap?
- c) Supón que se elimina la dummy correspondiente a *Tienda*. El modelo estimado queda:

$$\hat{y} = 500 + 120D_{\text{Web}} - 80D_{\text{Teléfono}}.$$

Calcula la predicción para una venta realizada mediante:

- I) tienda;
- II) web;
- III) teléfono.
- d) Interpreta los coeficientes dentro del contexto.
- e) ¿Cambiarían las predicciones si se utilizara *Web* como categoría de referencia? Explica qué cambiaría y qué permanecería igual.
- f) Explica por qué el problema del Dummy Variable Trap es especialmente relevante en modelos lineales.

Caso 4. Escalamiento de variables

Una institución financiera utiliza las siguientes dos variables:

Cliente	Edad	Ingreso mensual
A	20	10,000
B	30	20,000
C	40	30,000
D	50	40,000
E	60	50,000

Parte I. Normalización

Utiliza la transformación Min-Max:

$$x_i^{\text{norm}} = \frac{x_i - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}}.$$

- a) Calcula la edad normalizada de cada cliente y el ingreso normalizado de cada cliente.
- b) Verifica que los valores transformados se encuentren entre 0 y 1.
- c) ¿Qué observaciones toman los valores 0 y 1.
- d) Supón que aparece un nuevo cliente con ingreso de 70,000 pesos. Utiliza los valores mínimo y máximo originales para normalizarlo.
- e) ¿El resultado necesariamente se encontrará entre 0 y 1? Explica por qué.

Parte II. Estandarización

Utiliza:

$$z_i = \frac{x_i - \bar{x}}{s},$$

donde, para este ejercicio, utilizarás:

$$s = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- a) Estandariza las dos variables.
- b) Verifica que las variables estandarizadas tengan media igual a cero, salvo diferencias de redondeo.

Caso 5. Problema de integración: una predicción demasiado perfecta

Una empresa de telecomunicaciones desea predecir qué clientes cancelarán su servicio durante el próximo mes.

La base contiene las siguientes variables:

Variable	Descripción
<code>antiguedad</code>	Meses desde la contratación
<code>cargo_mensual</code>	Monto de la factura mensual
<code>numero_quejas</code>	Quejas registradas durante los últimos seis meses
<code>dias_sin_uso</code>	Días desde la última utilización del servicio
<code>tipo_contrato</code>	Mensual, anual o bianual
<code>ciudad</code>	Ciudad de residencia
<code>fecha_cancelacion</code>	Fecha en la que el cliente canceló el servicio
<code>motivo_cancelacion</code>	Motivo registrado después de la cancelación
<code>llamada_retencion</code>	Indica si el equipo de retención llamó al cliente
<code>descuento_retencion</code>	Descuento ofrecido para evitar la cancelación
<code>churn</code>	Indica si el cliente canceló durante el siguiente mes

Un analista construye un modelo y obtiene:

Accuracy de entrenamiento = 99.8 %,

Accuracy de validación = 99.5 %.

La dirección considera que el proyecto está terminado.

Parte I. Diseño de variables

a) Clasifica las variables como:

- numéricas;
- categóricas;
- temporales;
- variable objetivo.

b) Identifica cuáles variables requieren transformación.

c) Diseña una representación para `tipo_contrato`.

d) Explica cómo representarías `ciudad` si existieran:

- 1) 5 ciudades;

- II) 500 ciudades;
 - III) 100,000 ciudades.
- e) Propón al menos cuatro variables derivadas que podrían construirse sin utilizar información futura.

Parte II. Detectando Data Leakage

- a) Explica qué significa Data Leakage.
- b) Analiza si las siguientes variables estarían disponibles al momento de predecir la cancelación:
- I) `fecha_cancelacion`;
 - II) `motivo_cancelacion`;
 - III) `llamada_retencion`;
 - IV) `descuento_retencion`.
- c) Identifica cuáles variables contienen información posterior al evento que se desea predecir.
- d) Explica por qué incluirlas puede producir métricas artificialmente elevadas.
- e) ¿La variable `llamada_retencion` siempre representa leakage? Analiza cómo depende del momento exacto en que se realiza la predicción.
- f) Explica la diferencia entre:
- I) leakage directo;
 - II) leakage temporal;
 - III) leakage producido durante el preprocesamiento.
- g) Propón una explicación para la precisión casi perfecta obtenida por el modelo.

Parte III. Preprocesamiento correcto

La base se divide en entrenamiento, validación y prueba.

- a) ¿La media y la desviación estándar utilizadas para estandarizar variables deberían calcularse únicamente con el conjunto de entrenamiento? ¿Por qué?
- b) Supón que el ingreso promedio es:

$$\bar{x}_{\text{train}} = 20,000, \quad \bar{x}_{\text{total}} = 24,000.$$

¿Qué pasa si usas la media total de los datos para entrenar el modelo?

c) Diseña un orden correcto para las siguientes operaciones:

- dividir los datos;
 - calcular estadísticas de escalamiento;
 - transformar variables categóricas;
 - entrenar el modelo;
 - elegir hiperparámetros;
 - evaluar en prueba.
-