

Aprendizaje de Máquina

Tarea 6 K-Nearest Neighbors y Árboles de Decisión para Regresión

Braulio Piña Amaros

“No todos los modelos aprenden una ecuación: algunos predicen a partir de la semejanza y otros dividen el espacio en regiones.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Comparar modelos paramétricos y no paramétricos.
- Explicar el funcionamiento de K-Nearest Neighbors para regresión.
- Calcular manualmente distintas medidas de distancia.
- Analizar el efecto del hiperparámetro k sobre el ajuste y la generalización.
- Explicar por qué el escalamiento es importante en métodos basados en distancias.
- Construir manualmente predicciones mediante árboles de decisión para regresión.
- Evaluar posibles divisiones mediante el criterio de reducción del error cuadrático.
- Analizar criterios de parada, sobreajuste y poda.
- Explicar la maldición de la dimensionalidad y sus consecuencias.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos y desarrollos completos.
- No necesitas utilizar ningún lenguaje de programación.
- Puedes utilizar calculadora, las notas del curso y bibliografía adicional.

- Salvo que se indique lo contrario, conserva al menos cuatro decimales durante los cálculos.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. Distintas formas de aprender

Considera tres modelos utilizados para estimar el precio de una vivienda.

- **Modelo A:** una regresión lineal de la forma

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

- **Modelo B:** K-Nearest Neighbors, que predice utilizando las viviendas más parecidas.
 - **Modelo C:** un árbol de decisión, que divide las viviendas en grupos mediante reglas sucesivas.
- a) Explica qué significa que un modelo sea paramétrico y no paramétrico.
 - b) Clasifica los modelos A, B y C como paramétricos o no paramétricos.
 - c) ¿Qué aprende explícitamente el Modelo A durante el entrenamiento?
 - d) ¿Qué información necesita conservar el Modelo B después del entrenamiento?
 - e) Por qué suele afirmarse que KNN tiene una fase de entrenamiento muy sencilla, pero una fase de predicción costosa.
 - f) Describe qué aprende un árbol de decisión.
 - g) Compara los tres modelos en términos de:
 - I) interpretabilidad;
 - II) flexibilidad;
 - III) costo de predicción;
 - IV) sensibilidad al escalamiento;
 - V) capacidad para representar relaciones no lineales.
 - h) ¿Cuál de los tres modelos podría extrapolar más naturalmente fuera del rango de los datos observados? Explica las limitaciones de esa extrapolación.

Caso 2. K-Nearest Neighbors para regresión

Una empresa desea estimar el gasto mensual de un cliente utilizando dos variables:

- x_1 : antigüedad como cliente, medida en años;
- x_2 : número de compras realizadas durante el último mes.

La muestra disponible es:

Cliente	Antigüedad x_1	Compras x_2	Gasto y
A	1	2	200
B	2	3	260
C	3	2	280
D	4	5	430
E	5	4	410
F	6	6	520

Se desea estimar el gasto de un nuevo cliente:

$$x^* = (3, 4).$$

Utiliza inicialmente la distancia euclidiana:

$$d(x^*, x_i) = \sqrt{(x_1^* - x_{i1})^2 + (x_2^* - x_{i2})^2}.$$

- Calcula la distancia entre el nuevo cliente y cada observación.
- Ordena los clientes de menor a mayor distancia.
- Calcula la predicción para:

I) $k = 1$;

II) $k = 2$;

III) $k = 3$;

Utiliza el promedio simple:

$$\hat{y}(x^*) = \frac{1}{k} \sum_{i \in N_k(x^*)} y_i.$$

- Explica qué ocurre con la predicción conforme aumenta k .
- ¿Cuál utiliza una mayor proporción de la muestra?
- ¿Que pasa con la varianza de la predicción cuando disminuye k ?
- ¿Qué pasa con el sesgo cuando aumenta k ?
- Explica por qué KNN puede ser sensible a observaciones atípicas.

Promedio ponderado

En lugar del promedio simple, puede utilizarse una predicción ponderada:

$$\hat{y}(x^*) = \frac{\sum_{i \in N_k(x^*)} w_i y_i}{\sum_{i \in N_k(x^*)} w_i}, \quad w_i = \frac{1}{d(x^*, x_i)}.$$

- a) Utiliza los tres vecinos más cercanos y calcula la predicción ponderada.
- b) Compara el resultado con la predicción no ponderada para $k = 3$.
- c) Explica qué observaciones reciben mayor importancia.
- d) ¿Qué problema ocurre si una observación tiene distancia exactamente igual a cero?

Caso 3. Distancias y escalamiento

Una institución desea utilizar KNN para estimar el saldo de sus clientes. Las variables son:

- edad, medida en años;
- ingreso anual, medido en pesos.

Se consideran los siguientes clientes:

$$A = (25, 300,000),$$

$$B = (45, 320,000),$$

$$C = (26, 500,000).$$

El nuevo cliente es:

$$P = (27, 310,000).$$

Parte I. Distancia euclidiana

- a) Calcula:

$$d(P, A), \quad d(P, B), \quad d(P, C).$$

- b) Identifica cuál es el vecino más cercano.
- c) Analiza cuál variable domina la distancia.
- d) Desde una perspectiva intuitiva, ¿consideras que el resultado representa adecuadamente la semejanza entre los clientes? Justifica tu respuesta.

Parte II. Normalización

Supón que en la muestra de entrenamiento se observan:

$$\text{Edad mínima} = 20, \quad \text{Edad máxima} = 60,$$

$$\text{Ingreso mínimo} = 200,000, \quad \text{Ingreso máximo} = 600,000.$$

Utiliza:

$$x^{\text{norm}} = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}}.$$

- a) Normaliza las coordenadas de A , B , C y P .
- b) Calcula nuevamente las tres distancias euclidianas.
- c) Identifica el vecino más cercano después del escalamiento.
- d) Explica por qué el resultado puede cambiar.

Caso 4. Construyendo un árbol de regresión

Una empresa desea predecir el gasto mensual de sus clientes utilizando únicamente el número de compras realizadas durante el mes.

La muestra es:

Compras x_i	Gasto y_i
1	100
2	120
3	140
4	300
5	330
6	350

Un árbol de regresión divide los datos en regiones y asigna a cada hoja el promedio de las observaciones que contiene.

Para evaluar una división en el punto s , utiliza:

$$\text{SSE}(s) = \sum_{i:x_i \leq s} (y_i - \bar{y}_L)^2 + \sum_{i:x_i > s} (y_i - \bar{y}_R)^2,$$

donde $\bar{y}_L$ y $\bar{y}_R$ son los promedios de las regiones izquierda y derecha.
Considera como posibles puntos de corte:

$$s \in \{1.5, 2.5, 3.5, 4.5, 5.5\}.$$

- a) Calcula el promedio global de y .

b) Calcula el SSE del nodo raíz, antes de realizar cualquier división:

$$\text{SSE}_{\text{raz}} = \sum_{i=1}^n (y_i - \bar{y})^2.$$

c) Para cada valor de s :

- i) identifica las observaciones del nodo izquierdo;
- ii) identifica las observaciones del nodo derecho;
- iii) calcula $\bar{y}_L$;
- iv) calcula $\bar{y}_R$;
- v) calcula $\text{SSE}(s)$.

d) Organiza los resultados en la siguiente tabla:

Corte s	Promedio izquierdo	Promedio derecho	SSE total
1.5			
2.5			
3.5			
4.5			
5.5			

e) Identifica la mejor división.

f) Calcula la reducción del error:

$$\Delta \text{SSE} = \text{SSE}_{\text{raz}} - \text{SSE}(s).$$

g) Escribe la regla de predicción del árbol después de realizar una sola división.

h) Predice el gasto de clientes con:

$$x = 2.5, \quad x = 4, \quad x = 8.$$

i) Explica por qué las predicciones de un árbol de regresión son constantes dentro de cada hoja.

j) ¿Puede este árbol extrapolar una tendencia creciente para valores de x mayores que 6? ¿Por qué?

Caso 5. Profundidad, sobreajuste y poda

Se entrenan cuatro árboles de regresión utilizando los mismos datos.

Árbol	Profundidad	Hojas	MSE entrenamiento	MSE validación
A	1	2	18.5	19.1
B	3	6	8.2	9.0
C	7	20	1.4	7.8
D	15	85	0.0	21.6

- a) Identifica cuál árbol presenta mayor evidencia de subajuste.
 - b) Identifica cuál presenta mayor evidencia de sobreajuste.
 - c) ¿Cuál elegirías utilizando el error de validación?
 - d) Explica por qué el error de entrenamiento disminuye conforme aumenta la profundidad.
 - e) Explica por qué el error de validación puede comenzar a aumentar después de cierto punto.
 - f) Relaciona la profundidad del árbol con el compromiso entre sesgo y varianza.
 - g) Clasifica los árboles A y D en términos de:
 - I) sesgo;
 - II) varianza;
 - III) complejidad;
 - IV) estabilidad ante cambios en la muestra.
-