

Aprendizaje de Máquina

Tarea 7 Evaluación y Selección de Modelos de Regresión

Braulio Piña Amaros

“Una métrica no determina por sí sola si un modelo es bueno; sólo resume una parte de su comportamiento.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Calcular e interpretar las principales métricas de evaluación para regresión.
- Comparar MAE, MSE, RMSE, MAPE y R^2 .
- Analizar la sensibilidad de distintas métricas ante errores grandes y valores atípicos.
- Seleccionar una métrica de acuerdo con el objetivo del problema.
- Explicar el funcionamiento de K-Fold Cross Validation.
- Calcular manualmente resultados de validación cruzada.
- Analizar la variabilidad del desempeño entre particiones.
- Explicar el propósito de Repeated K-Fold.
- Comparar Grid Search y Random Search.
- Seleccionar hiperparámetros sin utilizar indebidamente el conjunto de prueba.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos y desarrollos completos.
- No necesitas utilizar ningún lenguaje de programación.

- Puedes utilizar calculadora, las notas del curso y bibliografía adicional.
- Salvo que se indique lo contrario, conserva al menos cuatro decimales durante los cálculos.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. Midiendo los errores de un modelo

Una empresa utiliza un modelo para estimar la demanda semanal de cinco productos. Los valores observados y predichos son:

Producto	Demanda observada y_i	Predicción $\hat{y}_i$	Residuo $e_i = y_i - \hat{y}_i$
A	100	90	10
B	120	135	-15
C	80	75	5
D	150	160	-10
E	50	40	10

Utiliza las siguientes métricas:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|.$$

- Calcula MAE, MSE, RMSE y MAPE.
- ¿Cuál de las métricas puede interpretarse directamente en las mismas unidades de la variable respuesta?
- Explica por qué MSE no se encuentra expresado en las mismas unidades que la demanda.
- Explica por qué RMSE puede resultar más fácil de interpretar que MSE.
- Analiza qué métrica utilizarías si el objetivo fuera comunicar el error promedio a un gerente sin formación técnica.
- Explica por qué ninguna de estas métricas permite distinguir por sí sola si el modelo tiende sistemáticamente a sobreestimar o subestimar.
- Propón una medida adicional que permita detectar sesgo sistemático en las predicciones.

Caso 2. Limitaciones de MAPE y R^2

Parte I. MAPE

Se observan los siguientes valores:

Observación	y_i	$\hat{y}_i$
1	100	90
2	10	8
3	1	2
4	0	1

- a) Calcula el error porcentual absoluto de las primeras tres observaciones.
- b) Explica por qué un error absoluto de una unidad produce consecuencias porcentuales muy distintas cuando:

$$y = 100, \quad y = 10, \quad y = 1.$$

- c) ¿Qué problema ocurre con MAPE cuando $y_i = 0$?
- d) ¿Qué problema ocurre cuando y_i es muy cercano a cero?
- e) Propón una alternativa cuando la variable respuesta contiene ceros.

Parte II. Coeficiente de determinación

El coeficiente de determinación se define como:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\text{SSE}}{\text{SST}}.$$

Considera los datos:

Observación	y_i	$\hat{y}_i$
1	2	3
2	4	4
3	6	5
4	8	7

- a) Calcula R^2 .
- b) Interpreta el resultado.
- c) Explica qué representa el modelo de referencia implícito en R^2 .

- d) ¿Qué valor de R^2 se obtendría si el modelo siempre predijera $\bar{y}$?
- e) Explica cómo puede aparecer un valor negativo de R^2 .
- f) ¿Puede un modelo tener un RMSE bajo y, al mismo tiempo, un R^2 bajo? Explica bajo qué circunstancias.
- g) ¿Puede un modelo tener un R^2 alto y errores económicamente inaceptables? Justifica tu respuesta.

Caso 4. K-Fold Cross Validation

Una empresa cuenta con 12 observaciones, identificadas como:

$$\{1, 2, 3, \dots, 12\}.$$

Desea utilizar validación cruzada con $K = 4$.

Una posible partición es:

$$F_1 = \{1, 2, 3\},$$

$$F_2 = \{4, 5, 6\},$$

$$F_3 = \{7, 8, 9\},$$

$$F_4 = \{10, 11, 12\}.$$

- a) Para cada iteración, identifica:
- i) el fold utilizado para validación;
 - ii) las observaciones utilizadas para entrenamiento.
- b) ¿Cuántas veces se entrena el modelo?
- c) ¿Cuántas veces aparece cada observación en validación?
- d) ¿Cuántas veces aparece cada observación en entrenamiento?
- e) ¿Qué proporción aproximada de los datos se utiliza para entrenamiento en cada iteración?

Los resultados de un modelo son:

Fold	RMSE de validación
1	4.2
2	5.1
3	4.7
4	8.0

- a) Calcula el RMSE promedio.
- b) Calcula la desviación estándar de los cuatro resultados utilizando:

$$s = \sqrt{\frac{1}{K} \sum_{k=1}^K (m_k - \bar{m})^2}.$$

- c) Interpreta el promedio.
- d) Interpreta la dispersión.
- e) Analiza el resultado del Fold 4.
- f) ¿Debería eliminarse automáticamente el Fold 4 del promedio? Justifica tu respuesta.
- g) Explica por qué reportar únicamente el promedio puede ocultar información importante.
- h) ¿Qué indica una baja variabilidad entre folds?
- i) ¿Qué indica una alta variabilidad?

Elección de K

- a) Explica cómo cambia el tamaño del conjunto de entrenamiento conforme aumenta K .
- b) Explica cómo cambia el costo computacional conforme aumenta K .
- c) ¿Un valor grande de K siempre es mejor? Argumenta tu respuesta.

Caso 5. Repeated K-Fold y selección de hiperparámetros

Se desea seleccionar el valor de k para un modelo KNN de regresión. Se evalúan:

$$k \in \{1, 3, 5, 9\}.$$

Se realizan tres repeticiones de 5-Fold Cross Validation. Los RMSE promedio de cada repetición son:

Repetición	$k = 1$	$k = 3$	$k = 5$	$k = 9$
1	12.4	9.1	8.5	10.2
2	14.0	8.8	8.7	9.8
3	11.6	9.5	8.6	10.5

- a) Calcula el RMSE promedio de cada valor de k considerando las tres repeticiones.
- b) ¿Qué valor de k presenta el menor error promedio?

- c) ¿Qué valor presenta mayor estabilidad entre repeticiones?
- d) ¿Cuál seleccionarías? Justifica tu respuesta utilizando tanto nivel como variabilidad del error.
- e) Explica por qué Repeated K-Fold puede proporcionar una evaluación más estable que una única ejecución de K-Fold.
- f) ¿Qué fuente de variabilidad intenta medir el procedimiento repetido?
- g) ¿Qué costo adicional introduce Repeated K-Fold?

Caso 6. Problema de integración: Grid Search o Random Search

Una empresa desea seleccionar los hiperparámetros de un árbol de decisión para regresión. Considera:

$$\text{max_depth} \in \{2, 4, 6, 8, 10\},$$

$$\text{min_samples_leaf} \in \{1, 5, 10, 20\},$$

$$\text{min_samples_split} \in \{2, 10, 25\}.$$

Parte I. Grid Search

- a) Calcula el número total de combinaciones del grid.
- b) Supón que se utiliza 5-Fold Cross Validation. ¿Cuántos entrenamientos son necesarios?
- c) Supón que cada entrenamiento tarda 30 segundos. Calcula el tiempo total aproximado en minutos.
- d) Explica una ventaja y una desventaja de Grid Search.
- e) ¿Grid Search garantiza encontrar el mejor hiperparámetro posible en todo el espacio? Justifica tu respuesta.

Parte II. Random Search

La empresa decide evaluar únicamente 20 combinaciones elegidas aleatoriamente.

- a) ¿Cuántos entrenamientos serán necesarios con 5 folds?
- b) Calcula el tiempo total aproximado si cada entrenamiento tarda 30 segundos.
- c) Compara el costo con Grid Search.

- d) Explica por qué Random Search puede explorar una mayor variedad de valores cuando existen muchos hiperparámetros. ¿Qué papel juega la definición de distribuciones de muestro de hiperparámetros?
- e) ¿Random Search garantiza encontrar la mejor combinación? Explica.
- f) ¿Por qué podría superar a Grid Search bajo un presupuesto computacional fijo?

Parte III. Comparación de configuraciones

Los mejores resultados encontrados son:

Método	Profundidad	Min. hoja	Min. división	RMSE CV
Grid Search	8	5	10	7.82
Random Search	7	8	12	7.79
Modelo simple	4	20	25	8.05

La desviación estándar entre folds es:

Modelo	Desviación estándar del RMSE
Grid Search	1.40
Random Search	1.95
Modelo simple	0.65

- a) ¿Qué modelo presenta el menor RMSE promedio?
- b) ¿Qué modelo presenta mayor estabilidad?
- c) ¿La diferencia entre 7.82 y 7.79 parece suficientemente grande para declarar que Random Search es claramente superior? Argumenta tu respuesta.
- d) ¿En qué situación preferirías el modelo simple?
- e) Menciona otros criterios relevantes para elegir entre modelos con desempeños similares.