

Aprendizaje de Máquina

Tarea 8 Clasificación y Regresión Logística

Braulio Piña Amaros

“Clasificar no consiste únicamente en asignar una etiqueta, sino en decidir bajo incertidumbre y asumir el costo de equivocarse.”

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Formular problemas de clasificación binaria, multiclase y multietiqueta.
- Distinguir un problema de regresión de uno de clasificación.
- Explicar el funcionamiento de un clasificador lineal.
- Calcular e interpretar probabilidades mediante la función logística.
- Relacionar probabilidades, umbrales y etiquetas predichas.
- Calcular la entropía cruzada binaria.
- Explicar por qué la regresión logística se entrena como un problema de optimización.
- Extender la clasificación binaria al caso multiclase mediante One-vs-Rest y Softmax.
- Construir e interpretar una matriz de confusión.
- Calcular accuracy, precision, recall y F_1 .
- Analizar el efecto del umbral de decisión.
- Construir e interpretar una curva ROC y su área bajo la curva.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos y desarrollos completos.
- No necesitas utilizar ningún lenguaje de programación.
- Puedes utilizar calculadora, las notas del curso y bibliografía adicional.
- Salvo que se indique lo contrario, conserva al menos cuatro decimales durante los cálculos.
- Se evaluará tanto la respuesta final como la claridad de tu razonamiento.

Caso 1. ¿Regresión o clasificación?

- a) ¿Cuál es la diferencia entre predecir una clase y estimar la probabilidad de pertenecer a esa clase?
- b) ¿Por qué convertir una variable continua en categorías puede provocar pérdida de información?
- c) Un analista propone utilizar una regresión lineal para predecir directamente una variable binaria codificada como 0 y 1. Menciona al menos tres problemas potenciales de esta estrategia.

Caso 2. De una combinación lineal a una probabilidad

Un banco utiliza un modelo de regresión logística para estimar la probabilidad de incumplimiento de un crédito.

El modelo es:

$$z = -4 + 0.03x_1 + 0.8x_2,$$

donde:

- x_1 representa el porcentaje de utilización de la línea de crédito;
- x_2 representa el número de pagos atrasados durante el último año.

La probabilidad estimada es:

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

- a) Explica qué representa el valor z .
- b) Calcula z y p para los siguientes clientes:

Cliente	Utilización x_1	Pagos atrasados x_2
A	20	0
B	50	1
C	80	2
D	100	4

- c) Utiliza un umbral de 0.5 para asignar la clase predicha:

$$\hat{y} = \begin{cases} 1, & p \geq 0.5, \\ 0, & p < 0.5. \end{cases}$$

Clasifica a los cuatro clientes.

- d) ¿Qué valor de z corresponde exactamente a una probabilidad de 0.5?

e) Muestra que:

$$\sigma(0) = 0.5.$$

f) Verifica que:

$$\sigma(-z) = 1 - \sigma(z).$$

g) Explica qué ocurre con la probabilidad cuando aumenta el número de pagos atrasados, manteniendo fija la utilización.

h) Interpreta el signo de los coeficientes 0.03 y 0.8.

Log-odds y odds

Las odds se definen como:

$$\text{odds} = \frac{p}{1-p},$$

y los log-odds como:

$$\log \left(\frac{p}{1-p} \right).$$

En regresión logística:

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

a) Calcula las odds correspondientes a:

$$p = 0.2, \quad p = 0.5, \quad p = 0.8.$$

b) Interpreta cada resultado en el contexto del problema de incumplimiento de crédito.

Caso 3. Entropía cruzada y entrenamiento

Para una observación con etiqueta:

$$y_i \in \{0, 1\},$$

y probabilidad estimada:

$$p_i = P(y_i = 1 \mid x_i),$$

la pérdida de entropía cruzada binaria es:

$$\ell_i = -[y_i \log(p_i) + (1 - y_i) \log(1 - p_i)].$$

a) Simplifica la pérdida cuando:

I) $y_i = 1$;

II) $y_i = 0$.

b) Calcula la pérdida cuando $y_i = 1$ y:

$$p_i = 0.9, \quad p_i = 0.6, \quad p_i = 0.1.$$

c) Calcula la pérdida cuando $y_i = 0$ y:

$$p_i = 0.1, \quad p_i = 0.4, \quad p_i = 0.9.$$

d) ¿Qué pasa con la pérdida cuando hay una predicción correcta y segura?

e) ¿Qué pasa con la pérdida cuando hay una predicción incorrecta y segura?

Un modelo produce las siguientes probabilidades:

Observación	Etiqueta y_i	Probabilidad p_i
1	1	0.90
2	0	0.20
3	1	0.60
4	0	0.80
5	1	0.40

a) Calcula la pérdida individual de cada observación.

b) Calcula la entropía cruzada promedio:

$$J = \frac{1}{n} \sum_{i=1}^n \ell_i.$$

c) Identifica la observación que recibe la mayor penalización. ¿Por qué?

d) Utiliza un umbral de 0.5 y calcula el accuracy.

e) ¿Es posible que dos modelos tengan el mismo accuracy, pero distinta entropía cruzada? Explica.

Caso 4. Clasificación multiclase

Una universidad desea clasificar a cada estudiante en una de tres categorías:

{Bajo riesgo, Riesgo medio, Alto riesgo}.

Parte I. One-vs-Rest

El método One-vs-Rest construye tres clasificadores:

- Bajo riesgo contra el resto;
- Riesgo medio contra el resto;
- Alto riesgo contra el resto.

Para un estudiante, los modelos producen:

$$p_{\text{Bajo}} = 0.25, \quad p_{\text{Medio}} = 0.55, \quad p_{\text{Alto}} = 0.40.$$

- a) ¿Qué clase asignarías utilizando la probabilidad más alta?
- b) Suma las tres probabilidades.
- c) ¿Por qué las probabilidades de modelos One-vs-Rest no necesariamente suman uno?
- d) Explica una ventaja y una desventaja de One-vs-Rest.
- e) ¿Cuántos clasificadores binarios se necesitan para un problema con K clases?

Parte II. Softmax

La función Softmax transforma los puntajes:

$$z_1, z_2, \dots, z_K$$

en probabilidades:

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}.$$

Considera los puntajes:

$$z_{\text{Bajo}} = 1, \quad z_{\text{Medio}} = 2, \quad z_{\text{Alto}} = 0.$$

- a) Calcula:

$$e^1, \quad e^2, \quad e^0.$$

- b) Calcula las tres probabilidades Softmax.
- c) Verifica que sumen uno.
- d) Identifica la clase predicha.
- e) Explica por qué la clase con mayor puntaje también tiene la mayor probabilidad.

f) Suma una constante $c = 10$ a todos los puntajes:

$$z'_k = z_k + 10.$$

Calcula nuevamente las probabilidades. ¿Qué observas?

g) Demuestra algebraicamente que Softmax es invariante a sumar la misma constante a todos los puntajes.

Caso 5. Métricas, umbrales y costos

Un hospital utiliza un modelo para detectar una enfermedad. En una muestra de 1,000 pacientes:

- 100 tienen la enfermedad;
- 900 no la tienen.

Con un umbral determinado, el modelo produce:

- 80 verdaderos positivos;
- 20 falsos negativos;
- 90 falsos positivos;
- 810 verdaderos negativos.

La matriz de confusión es:

	Predicción positiva	Predicción negativa
Real positiva	80	20
Real negativa	90	810

Utiliza:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}},$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}},$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}},$$

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

- a) Calcula accuracy.
- b) Calcula precision.

- c) Calcula recall.
- d) Calcula F_1 .
- e) Interpreta cada métrica dentro del contexto médico.
- f) ¿Qué proporción de los pacientes diagnosticados como positivos realmente tiene la enfermedad?
- g) ¿Qué proporción de los pacientes enfermos fue detectada?
- h) ¿Cuál de los dos errores considerarías más grave en un sistema de detección inicial? Justifica tu respuesta.

El problema del desbalance

Considera un modelo ingenuo que clasifica a todos los pacientes como sanos.

- a) Construye su matriz de confusión.
- b) Calcula su accuracy.
- c) Calcula su recall para la clase positiva.
- d) ¿Elegirías el modelo al tener un alto accuracy? ¿Por que?

El efecto del umbral

El modelo produce probabilidades de enfermedad. Se comparan tres umbrales:

Umbral	TP	FN	FP	TN
0.30	95	5	250	650
0.50	80	20	90	810
0.70	55	45	30	870

- a) Calcula precision y recall para cada umbral.
- b) Describe qué ocurre con el recall conforme aumenta el umbral.
- c) Describe qué ocurre con la precision.
- d) Explica por qué disminuir el umbral tiende a producir más predicciones positivas.
- e) ¿Qué umbral elegirías si el objetivo principal fuera no dejar pasar pacientes enfermos?
- f) ¿Qué umbral elegirías si una prueba confirmatoria fuera muy costosa e invasiva?

Caso 6. Problema de integración: riesgo crediticio

Un banco desarrolla un modelo para predecir incumplimiento crediticio. Para diez clientes, se observan las siguientes probabilidades y etiquetas reales:

Cliente	Probabilidad de incumplimiento	Etiqueta real
A	0.95	1
B	0.85	0
C	0.80	1
D	0.70	1
E	0.65	0
F	0.55	1
G	0.40	0
H	0.30	1
I	0.20	0
J	0.10	0

Parte I. Matrices de confusión

- Utiliza un umbral de 0.5, 0.7 y 0.3 para calcular la clase predicha de cada cliente.
- ¿Cuál elegirías si aprobar un crédito a un cliente que incumplirá genera un costo muy elevado?
- ¿Cuál elegirías si rechazar a un buen cliente representa el mayor costo comercial?

Parte II. Curva ROC

La tasa de verdaderos positivos es:

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}},$$

y la tasa de falsos positivos es:

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}.$$

- Dibuja la curva ROC
- Explica qué representa el punto (0,0).
- Explica qué representa el punto (1,1).
- ¿Por qué el punto ideal es (0,1)?
- Explica qué representa la diagonal:

$$\text{TPR} = \text{FPR}.$$

Parte III. Área bajo la curva

- a) Aproxima el área bajo la curva ROC.
 - b) Explica por qué AUC no depende de un único umbral.
 - c) Explica la interpretación probabilística de AUC como la probabilidad de que una observación positiva reciba un puntaje mayor que una observación negativa elegida al azar.
 - d) ¿Qué significa aproximadamente:
 - i) $AUC = 0.5$;
 - ii) $AUC = 1$;
 - iii) $AUC < 0.5$?
 - e) Dos modelos tienen el mismo AUC, pero uno produce probabilidades bien calibradas y el otro no. ¿Puede AUC distinguirlos? Explica.
 - f) ¿Un modelo con mayor AUC siempre tendrá mejor accuracy para un umbral de 0.5? Justifica tu respuesta.
-