

Aprendizaje de Máquina

Tarea 9

Métodos de Clasificación Basados en Vecinos, Árboles y Márgenes

Braulio Piña Amaros

Existen muchas formas de construir una frontera de decisión. Lo importante no es únicamente clasificar correctamente, sino comprender cómo aprende cada algoritmo.

Problema 1. K-Nearest Neighbors para clasificación

Una empresa desea clasificar clientes como **Premium (P)** o **Estándar (E)** utilizando dos variables:

- Número de compras durante el último mes.
- Gasto promedio por compra.

La información disponible es la siguiente:

Cliente	Compras	Gasto	Clase
<i>A</i>	2	3	<i>E</i>
<i>B</i>	3	4	<i>E</i>
<i>C</i>	4	2	<i>E</i>
<i>D</i>	6	7	<i>P</i>
<i>E</i>	7	6	<i>P</i>
<i>F</i>	8	8	<i>P</i>

Se desea clasificar al nuevo cliente

$$x^* = (5, 5).$$

Utiliza distancia Euclidiana.

1. Calcula la distancia entre el nuevo cliente y cada una de las observaciones disponibles. Ordena posteriormente las observaciones de menor a mayor distancia.
2. Para $k = 1$, $k = 3$ y $k = 5$, determina la clase predicha para x^* .

3. En KNN podemos estimar la probabilidad de pertenecer a la clase Premium mediante

$$\hat{P}(Y = P \mid X = x) = \frac{1}{k} \sum_{i \in N_k(x)} \mathbb{I}(Y_i = P),$$

donde $N_k(x)$ representa el conjunto de los k vecinos más cercanos a x .

Para $k = 1$, $k = 3$ y $k = 5$, calcula

$$\hat{P}(Y = P \mid X = x^*)$$

y

$$\hat{P}(Y = E \mid X = x^*).$$

Comprueba que la clasificación obtenida coincide con la regla

$$\hat{y} = \begin{cases} P, & \hat{P}(Y = P \mid X = x) > 0.5, \\ E, & \text{en otro caso.} \end{cases}$$

4. Supón que las clases se codifican como

$$Y_i = \begin{cases} 1, & \text{si el cliente es Premium,} \\ 0, & \text{si el cliente es Estándar.} \end{cases}$$

Explica por qué

$$\hat{P}_k(Y = 1 \mid X = x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i$$

corresponde exactamente a la proporción de vecinos pertenecientes a la clase Premium.

5. Sin utilizar el conjunto de datos anterior, determina **todos los posibles valores** que puede tomar $\hat{P}(Y = P \mid X = x)$ cuando:

a) $k = 1$,

b) $k = 3$,

c) $k = 5$.

A partir de tus resultados, escribe el conjunto de posibles probabilidades para un valor general de k .

Problema 2. Árboles de decisión para clasificación

Considera un problema de clasificación binaria. En cierto nodo de un árbol de decisión existen 100 observaciones distribuidas de la siguiente manera:

$$n_0 = 50, \quad n_1 = 50.$$

El árbol considera dos posibles divisiones.

Split A			Split B		
	$Y = 0$	$Y = 1$		$Y = 0$	$Y = 1$
Nodo izquierdo	40	10	Nodo izquierdo	30	20
Nodo derecho	10	40	Nodo derecho	20	30

Para medir la impureza de un nodo utiliza el índice de Gini:

$$G(t) = 1 - \sum_{j=1}^C p_j^2,$$

donde p_j representa la proporción de observaciones de la clase j dentro del nodo.

1. Calcula la impureza de Gini del nodo padre.
2. Calcula la impureza de Gini de cada nodo hijo producido por el **Split A**.
3. Calcula la impureza de Gini de cada nodo hijo producido por el **Split B**.
4. La impureza de una división se calcula como

$$G_{\text{split}} = \frac{n_L}{n} G_L + \frac{n_R}{n} G_R,$$

donde n_L y n_R representan el número de observaciones en los nodos izquierdo y derecho, respectivamente.

Calcula G_{split} para ambas divisiones y determina cuál seleccionaría el árbol. Justifica matemáticamente tu respuesta.

5. Después de entrenar un árbol, una nueva observación x^* termina en una hoja que contiene

$$n_0 = 8, \quad n_1 = 32.$$

Calcula

$$\hat{P}(Y = 0 \mid X = x^*)$$

y

$$\hat{P}(Y = 1 \mid X = x^*).$$

¿Qué clase predeciría el árbol?

6. Considera ahora las siguientes dos hojas:

	$Y = 0$	$Y = 1$
Hoja A	1	4
Hoja B	20	80

- Calcula $\hat{P}(Y = 1 \mid X = x)$ para ambas hojas.
- ¿Producen el mismo valor de `predict_proba`?
- Aunque el resultado numérico sea el mismo, ¿considerarías que ambas estimaciones tienen la misma estabilidad? Justifica.

Problema 3. Máquinas de Vectores de Soporte

Una empresa desea clasificar correos electrónicos como **Spam** (S) o **No Spam** (N) utilizando dos variables:

- x_1 : número de enlaces contenidos en el correo.
- x_2 : número de palabras promocionales.

Se propone el siguiente hiperplano:

$$2x_1 - x_2 - 3 = 0.$$

Recuerda que:

$$2x_1 - x_2 - 3 > 0$$

corresponde a la clase **Spam**, mientras que

$$2x_1 - x_2 - 3 < 0$$

corresponde a la clase **No Spam**.

Considere las siguientes observaciones.

Correo	x_1	x_2
A	1	1
B	2	0
C	3	2
D	4	3
E	5	5
F	2	4

Responde lo siguiente.

1. Calcula el valor de

$$2x_1 - x_2 - 3$$

para cada observación.

2. Clasifica cada correo utilizando el signo obtenido.
3. Identifica cuáles observaciones quedan exactamente sobre el hiperplano, si existen.
4. Si existen varios hiperplanos capaces de separar correctamente ambas clases, ¿por qué SVM selecciona únicamente uno?
5. Explica por qué un margen grande suele conducir a una mejor capacidad de generalización.

Problema 4. Vectores de soporte y Kernels

Considera el siguiente conjunto de observaciones.

- Dos grupos de puntos forman dos circunferencias concéntricas.
- La clase positiva corresponde al círculo interior.
- La clase negativa corresponde al círculo exterior.

Responde las siguientes preguntas.

1. ¿Qué ocurriría si intentáramos utilizar una SVM lineal sobre estos datos?
 2. Explica cómo utilizarías un **kernel**.
-