Aprendizaje de Máquina

Tarea 10

Reducción de Dimensionalidad y Análisis de Componentes Principales (PCA)

Braulio Piña Amaros

Reducir la dimensionalidad no significa perder información innecesariamente, sino conservar aquello que mejor explica la variabilidad de los datos."

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar por qué reducir la dimensionalidad.
- Interpretar geométricamente PCA.
- Comprender el concepto de componente principal.
- Analizar la varianza explicada.
- Decidir cuántos componentes conservar.
- Explicar cuándo utilizar PCA antes de otros algoritmos.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos necesarios.
- No utilices software.

Problema 1. ¿Por qué reducir la dimensionalidad?

Una empresa dispone de una base con 80 variables para describir a cada cliente.
Responde.

1. Explica tres problemas que pueden surgir al trabajar con un número muy grande de variables.

2. ¿Qué significa reducir la dimensionalidad?

3. ¿Reducir dimensionalidad implica necesariamente perder información? Justifica.

Problema 2. Interpretación geométrica de PCA

Considera un conjunto de observaciones con dos variables altamente correlacionadas. Responde.

1. Explica qué representa el primer componente principal.

2. Explica qué representa el segundo componente principal.

3. ¿Cuál componente explica la mayor parte de la variabilidad?

4. Si las dos variables fueran completamente independientes, ¿esperarías una gran reducción de dimensionalidad? Justifica.

5. Explica por qué PCA busca direcciones de máxima varianza.

6. ¿Significa una mayor varianza que una variable sea más importante para un problema predictivo? Argumenta.

Problema 3. Varianza explicada

Supón que un PCA produce los siguientes porcentajes de varianza explicada.

Componente	Varianza explicada
PC1	58 %
PC2	24 %
PC3	10 %
PC4	5 %
PC5	3 %

Responde.

1. Calcula la varianza acumulada para cada componente.

2. ¿Cuántos componentes conservarías si el criterio fuera explicar al menos el 80 % de la variabilidad?

3. ¿Y si el criterio fuera 90 %?

4. ¿Qué significa que un componente explique únicamente el 3 % de la varianza?

5. Explica por qué normalmente los primeros componentes contienen la mayor parte de la información.

6. ¿Siempre conviene conservar todos los componentes? Justifica.

7. Explica qué información podría perderse al eliminar componentes.

Problema 4. Interpretación y aplicaciones

Una empresa desea segmentar clientes utilizando K-Means.
Inicialmente dispone de 120 variables.
Después de aplicar PCA conserva únicamente 12 componentes principales que explican el 92 % de la varianza.

1. Explica una ventaja de aplicar PCA antes de K-Means.

2. Explica una posible desventaja.

3. ¿Por qué PCA puede reducir el efecto de variables altamente correlacionadas?

4. ¿Siempre mejora el desempeño de K-Means? Justifica.

5. ¿Aplicarías PCA antes de un árbol de decisión? Explica.

6. ¿Aplicarías PCA antes de una regresión logística? ¿En qué situaciones?

7. Explica por qué los componentes principales suelen ser más difíciles de interpretar que las variables originales.
