# Aprendizaje de Máquina

Tarea 11
Aprendizaje No Supervisado y K-Means

Braulio Piña Amaros

---

*Cuando no existen etiquetas, el objetivo deja de ser predecir y pasa a ser descubrir estructura en los datos.*

---

## Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Diferenciar problemas supervisados y no supervisados.
- Identificar cuándo utilizar clustering.
- Ejecutar manualmente el algoritmo K-Means.
- Interpretar el significado de los centroides.
- Explicar el comportamiento y las limitaciones del algoritmo.

## Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos necesarios.
- No utilices software para resolver la tarea.
- Puedes utilizar calculadora y las notas del curso.

## Problema 1. ¿Cuándo utilizar clustering?

Para cada uno de los siguientes escenarios responde:

1. ¿Se trata de un problema de aprendizaje supervisado o no supervisado?

2. Si es un problema no supervisado, ¿el clustering sería una herramienta adecuada? Justifica.

3. Propón al menos tres variables que utilizarías para construir los grupos.

Analiza los siguientes casos.

1. Una empresa desea segmentar a sus clientes según sus hábitos de compra.

2. Un periódico quiere agrupar automáticamente miles de noticias por temática.

3. Un banco desea predecir si un cliente incumplirá un crédito.

4. Un hospital busca identificar perfiles similares de pacientes con enfermedades crónicas.

## Problema 2. Primera iteración de K-Means

Se desea segmentar clientes utilizando dos variables:

- $x_1$: número de compras durante el último mes.
- $x_2$: gasto promedio por compra.

Se observan los siguientes clientes.

| Cliente | $x_1$ | $x_2$ |
|---|---|---|
| A | 1 | 2 |
| B | 2 | 1 |
| C | 2 | 3 |
| D | 6 | 7 |
| E | 7 | 6 |
| F | 8 | 8 |
| G | 6 | 5 |
| H | 7 | 8 |

Se utilizarán dos centroides iniciales:

$$C_1 = (2, 2)$$

$$C_2 = (7, 7)$$

La distancia Euclidiana entre dos puntos está dada por

$$d(x_i, x_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2}.$$

Responde lo siguiente.

1. Calcula la distancia de cada observación a ambos centroides.

2. Asigna cada observación al centroide más cercano.

3. Resume las asignaciones en una tabla.

4. Calcula el nuevo centroide de cada grupo utilizando el promedio de las coordenadas de las observaciones asignadas.

5. Escribe las coordenadas de los nuevos centroides.

6. Explica por qué los centroides cambian de posición después de la primera iteración.

7. Explica qué ocurriría si una observación estuviera exactamente a la misma distancia de ambos centroides.

8. Describe con tus propias palabras qué intenta minimizar el algoritmo K-Means durante el entrenamiento.

## Problema 3. Propiedades y limitaciones de K-Means

Responde las siguientes preguntas.

1. Explica por qué K-Means requiere definir previamente el número de clusters $K$.

2. ¿Qué podría ocurrir si eliges un valor de $K$ demasiado pequeño?

3. ¿Qué podría ocurrir si eliges un valor de $K$ demasiado grande?

4. Explica por qué K-Means es sensible a observaciones atípicas.

5. Considera un cluster formado por los puntos:

$$(1, 1), \qquad (2, 2), \qquad (3, 3).$$

Calcula su centroide.

6. Agrega ahora el punto atípico:

$$(20, 20).$$

Calcula nuevamente el centroide y analiza el cambio.

7. Explica por qué conviene escalar las variables antes de aplicar K-Means cuando se encuentran en unidades muy diferentes.

8. Supón que una variable representa edad en años y otra ingreso anual en pesos. ¿Cuál de las dos dominaría la distancia Euclidiana si no aplicas escalamiento?