Aprendizaje de Máquina

Tarea 12
Evaluación de Clusters

Braulio Piña Amaros

Encontrar grupos no es suficiente; también debemos preguntarnos si esos grupos realmente tienen sentido.

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar por qué elegir el número de clusters es un problema.
- Interpretar el método del codo.
- Calcular el WCSS.
- Calcular el Silhouette Score de observaciones individuales.
- Comparar distintos criterios para evaluar un clustering.

Instrucciones

- Justifica todas tus respuestas.
- Muestra todos los cálculos.

Problema 1. El costo de un clustering

Supón que K-Means produjo los siguientes dos clusters.
Cluster 1

$$(1, 2), (2, 1), (2, 3)$$

Centroide

$$(1.67, 2)$$

Cluster 2

$$(6,7),(7,6),(8,8)$$

Centroide

$$(7,7)$$

La función objetivo es

$$WCSS = \sum d(x_i, c_j)^2$$

Responde.

1. Calcula el aporte al WCSS de cada observación.
2. Calcula el WCSS del Cluster 1.
3. Calcula el WCSS del Cluster 2.
4. Calcula el WCSS total.
5. Explica qué representa este valor.
6. ¿Un WCSS grande es deseable?
7. ¿Qué ocurre con WCSS cuando aumenta el número de clusters?
8. ¿Qué valor tendría WCSS si cada observación formara su propio cluster?

Problema 2. Método del codo

Una empresa obtiene los siguientes resultados.

K	WCSS
1	1200
2	620
3	330
4	250
5	210
6	185

Responde.

1. Dibuja una gráfica aproximada de WCSS contra K.
2. Identifica el posible codo.

3. ¿Qué valor de K elegirías?

4. Explica por qué WCSS siempre disminuye conforme aumenta K.

5. ¿Por qué no elegir simplemente el valor más grande de K?

6. ¿Siempre existe un codo claramente definido? ¿Por qué?.

Problema 3. Silhouette Score

Para una observación se conocen los siguientes valores.

$$a = 1.8$$

$$b = 4.5$$

donde

- a es la distancia promedio a las observaciones de su mismo cluster.
- b es la distancia promedio al cluster vecino más cercano.

El índice Silhouette está dado por

$$s = \frac{b - a}{\text{máx}(a, b)}.$$

Responde.

1. Calcula el índice Silhouette.

2. ¿Qué significa un valor cercano a 1?

3. ¿Qué significa un valor cercano a 0?

4. ¿Qué significa un valor negativo?

5. Calcula el índice cuando

$$a = 4, \qquad b = 2.$$

6. Interpreta este resultado.

7. Explica qué observaciones deberían preocuparnos durante un análisis de clustering.

Problema 4. Comparando criterios

Tres segmentaciones producen los siguientes resultados.

Modelo	WCSS	Silhouette
A	420	0.74
B	350	0.39
C	300	0.18

Responde.

1. ¿Qué modelo tiene menor WCSS?
2. ¿Qué modelo tiene mayor Silhouette?
3. Si únicamente observaras WCSS, ¿cuál elegirías?
4. Si únicamente observaras Silhouette, ¿cuál elegirías?
5. Explica por qué ambos criterios pueden conducir a conclusiones distintas.
6. ¿Cuál considerarías más útil para elegir K? Justifica.
7. ¿Qué otras características revisarías antes de aceptar una segmentación?
