Aprendizaje de Máquina

Tarea 13
Clustering Basado en Densidad (DBSCAN)

Braulio Piña Amaros

No todos los grupos tienen forma esférica. Algunos aparecen simplemente porque existe una región con alta concentración de observaciones.

Objetivos

Al finalizar esta tarea deberías ser capaz de:

- Explicar el funcionamiento general de DBSCAN.
- Identificar puntos núcleo, frontera y ruido.
- Analizar el efecto de ε y MinPts.
- Comparar DBSCAN con K-Means.
- Identificar escenarios donde DBSCAN resulta más apropiado.

Instrucciones

- Justifica todas tus respuestas.
- Muestra los cálculos necesarios.
- No utilices software.

Problema 1. Construyendo clusters mediante densidad

Considera las siguientes observaciones.

$$A = (1, 1)$$

$$B = (1, 2)$$

$$C = (2, 1)$$

$$D = (2, 2)$$

$$E = (7, 7)$$

$$F = (7, 8)$$

$$G = (8, 7)$$

$$H = (15, 15)$$

Supón que DBSCAN utiliza

$$\varepsilon = 1.5$$

y

$$MinPts = 3.$$

Responde.

1. Calcula los vecinos de cada observación.
2. Identifica cuáles son puntos núcleo.
3. Identifica cuáles son puntos frontera.
4. Identifica cuáles serían considerados ruido.
5. Determina cuántos clusters encuentra DBSCAN.
6. Explica por qué la observación H es tratada de forma distinta.
7. ¿Qué diferencia existe entre un punto frontera y un punto de ruido?
8. Explica cómo construye DBSCAN un cluster.

Problema 2. Efecto de los hiperparámetros

Utiliza nuevamente las observaciones anteriores.
Responde.

1. ¿Qué ocurriría si aumentamos

$$\varepsilon$$

   a 3?

2. ¿Qué ocurriría si disminuimos

$$\varepsilon$$

   a 0.5?

3. ¿Qué efecto tiene aumentar MinPts?

4. ¿Qué efecto tiene disminuir MinPts?

Problema 3. K-Means vs DBSCAN

Responde las siguientes preguntas.

1. ¿Cuál algoritmo suele funcionar mejor cuando los clusters tienen forma aproximadamente circular?

2. ¿Cuál algoritmo puede detectar clusters con formas arbitrarias?

3. ¿Cuál algoritmo suele verse más afectado por valores atípicos?

4. ¿Cuál algoritmo resulta más adecuado cuando no conocemos el número de grupos?

5. Menciona dos ventajas y dos desventajas de cada algoritmo.
