Tarea 14
Métodos de Ensamble

Instrucciones

Justifica claramente cada una de tus respuestas. No es suficiente indicar únicamente la opción correcta; se evaluará el razonamiento empleado.

Problema 1. Sesgo, varianza y correlación

Considera un ensamble formado por B árboles de decisión.

Supón que, para un punto fijo x, las predicciones de cada árbol tienen varianza σ^2 y que la correlación entre las predicciones de cualquier par de árboles distintos es ρ.

El estimador del ensamble está definido por:

$$\hat{f}_{\text{ens}}(x) = \frac{1}{B}\sum_{b=1}^{B} \hat{f}_b(x).$$

a) Considera un ensamble de B árboles independientes, cada uno con varianza σ^2.

Demuestra que la varianza de su predicción promedio es:

$$\boxed{\text{Var}\left(\hat{f}_{\text{ens}}(x)\right) = \frac{\sigma^2}{B}}$$

Explica qué sucede con la varianza cuando aumenta el número de árboles.

Hint: Recuerda las siguientes propiedades de la varianza:

$$\text{Var}(aX) = a^2\,\text{Var}(X)$$

y, si $X_1, \ldots, X_B$ son variables aleatorias independientes,

$$\text{Var}\left(\sum_{b=1}^{B} X_b\right) = \sum_{b=1}^{B} \text{Var}(X_b).$$

b) En la práctica, los árboles de un Random Forest no son completamente independientes.

Si todos tienen varianza σ^2 y correlación común ρ, la varianza del ensamble está dada por:

$$\mathrm{Var}\left(\hat{f}_{\mathrm{ens}}(x)\right) = \sigma^2\left(\rho + \frac{1-\rho}{B}\right).$$

Considera $B = 20$ y $\rho = 0{,}25$.

i) Calcula la varianza del ensamble en función de σ^2.

ii) Determina el límite de la varianza cuando $B \to \infty$.

iii) Explica por qué la correlación entre árboles limita la reducción de varianza y cómo Random Forest intenta disminuir dicha correlación.

c) Considera dos Random Forest con el mismo número de árboles y el mismo conjunto de entrenamiento.

El primero considera todas las variables en cada división y el segundo considera únicamente $\sqrt{p}$ variables, donde p es el número total de predictores.

¿Cuál esperas que tenga mayor correlación entre árboles? ¿Cuál podría presentar mayor sesgo?

Justifica por qué reducir la correlación no garantiza necesariamente un menor error de generalización.

d) Explica por qué aumentar indefinidamente el número de árboles de Random Forest no garantiza reducir indefinidamente el error de predicción.

Contrasta este comportamiento con aumentar el número de etapas en Gradient Boosting.

Problema 2. Random Forest y predicciones probabilísticas

Considera un problema de clasificación binaria con n observaciones y $p = 16$ variables predictoras.

a) Se consideran tres configuraciones para el hiperparámetro `max_features`:

$$m \in \{16, 4, 1\}.$$

Explica cómo esperas que cambien:

- La diversidad de los árboles.
- La capacidad de seleccionar divisiones informativas.
- El compromiso entre sesgo y varianza.

¿Por qué no es necesariamente óptimo utilizar $m = 1$?

b) Tres árboles de un ensamble producen las siguientes probabilidades para una observación:

Árbol	$\boldsymbol{P(Y = 1 \mid x)}$
1	0.95
2	0.40
3	0.40

Calcula la clasificación obtenida mediante:

i) Voto mayoritario de las clases predichas individualmente.

ii) Promedio de las probabilidades, utilizando un umbral de 0,5.

¿Coinciden ambas predicciones?

Explica por qué el método `predict_proba` de un Random Forest no debe confundirse con la proporción de árboles que predicen cada clase.

Problema 3. Gradient Boosting para clasificación

Considera un problema de clasificación binaria con seis observaciones y etiquetas:

$$\mathbf{y} = (1, 1, 0, 1, 0, 0).$$

Se entrena un Gradient Boosting utilizando la función de pérdida logarítmica:

$$\ell(y_i, F(x_i)) = -y_i \log(p_i) - (1 - y_i) \log(1 - p_i),$$

donde:

$$p_i = \frac{1}{1 + e^{-F(x_i)}}.$$

La función de pérdida promedio es:

$$\mathcal{L}(F) = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, F(x_i)).$$

a) Demuestra que el gradiente negativo y la segunda derivada de la pérdida respecto de $F(x_i)$ son:

$$\boxed{r_i = -\frac{\partial \ell_i}{\partial F(x_i)} = y_i - p_i}$$

y

$$\boxed{h_i = \frac{\partial^2 \ell_i}{\partial F(x_i)^2} = p_i(1-p_i)}$$

Explica por qué el algoritmo ajusta árboles a los pseudo-residuos y no directamente a las etiquetas originales.

b) Determina el valor constante inicial F_0 que minimiza la pérdida logarítmica del conjunto.

Calcula las probabilidades iniciales y los pseudo-residuos correspondientes a cada observación.

c) Supón que el primer árbol divide las observaciones en dos hojas:

$$R_1 = \{1, 2, 3\}, \qquad R_2 = \{4, 5, 6\}.$$

Utilizando una actualización de Newton, sin regularización adicional, calcula el valor correspondiente a cada hoja:

$$\boxed{\gamma_j = \frac{\sum_{i \in R_j} (y_i - p_i)}{\sum_{i \in R_j} p_i(1-p_i)}}$$

Explica por qué estos valores no coinciden necesariamente con el promedio de los pseudo-residuos de la hoja.

d) Con una tasa de aprendizaje $\nu = 0{,}3$, actualiza el ensamble mediante:

$$\boxed{F_1(x) = F_0(x) + \nu\gamma_j, \qquad x \in R_j}$$

Calcula:

I) Los nuevos valores de $F_1(x_i)$.

II) Las nuevas probabilidades $\hat{p}_i^{(1)}$.

III) Los nuevos pseudo-residuos.

IV) La nueva pérdida logarítmica promedio del conjunto.

Determina si la pérdida disminuyó respecto de la iteración inicial.

e) ¿Qué podría suceder si se utiliza una tasa de aprendizaje demasiado grande?

Explica la relación entre los hiperparámetros `learning_rate`, `n_estimators`, el sobreajuste y la capacidad de generalización.

Problema 4. Evaluación, sobreajuste y selección de modelos

Se entrenaron cuatro modelos sobre el mismo problema de clasificación binaria.
Los resultados fueron los siguientes:

Modelo	**Log Loss train**	**Log Loss validación**	**AUC validación**
Árbol individual	0.09	0.69	0.75
Random Forest	0.19	0.43	0.85
Gradient Boosting A	0.02	0.62	0.86
Gradient Boosting B	0.27	0.46	0.89

Gradient Boosting A utiliza 500 etapas y `learning_rate` = 0,3.
Gradient Boosting B utiliza 100 etapas y `learning_rate` = 0,05.

a) Identifica qué modelos presentan mayor evidencia de sobreajuste.

   Justifica utilizando simultáneamente los resultados de entrenamiento y validación.

b) Si el objetivo es minimizar la pérdida logarítmica, ¿qué modelo elegirías?

   ¿Cambiaría tu decisión si el objetivo fuera maximizar el AUC?

   Explica por qué estas métricas pueden conducir a decisiones diferentes.

c) Supón que Gradient Boosting A tiene mayor capacidad de representación que Gradient Boosting B.

   ¿Por qué una mayor capacidad no garantiza un mejor rendimiento fuera de muestra?

d) Un compañero afirma:

   > *"Gradient Boosting siempre es superior a Random Forest porque corrige secuencialmente los errores de los árboles anteriores".*

   Evalúa críticamente esta afirmación.

   En tu respuesta, incorpora el compromiso sesgo-varianza y relaciona tu argumento con el teorema **No Free Lunch**.